Projekt: „Zaprojektowanie i opracowanie przez PKO BP systemu predykcyjnego umożliwiającego przewidywanie wartości wybranych aktywów cyfrowych” Numer projektu: FENG.01.01-IP.01-A059/23

Raport z realizacji zadania 1.4

Potok modeli uczenia maszynowego i sztucznej inteligencji

Wersja: 1,0
Data: 30.10.2026

Spis treści

1 Podsumowanie zarządcze **3**

2 Cel i zakres zadania **4**

3 Zakres wskaźników i modeli **4**

4 Dane **5**

4.1 Źródła danych 5

4.2 Charakterystyka danych według wskaźników 6

4.3 Zasady przygotowania danych 8

4.4 Kontrola jakości danych i doświadczenia z pracy na danych 8

5 Wstępne uczenie, kalibracja i testy lokalne **9**

5.1 Sposób prowadzenia testów 9

5.2 Zakres kalibracji 10

5.3 Benchmark i metryki 11

5.4 Charakter etapu i interpretacja wyników 11

6 Przekazanie i uruchomienie modeli w infrastrukturze banku **12**

6.1 Różnica między środowiskiem lokalnym a infrastrukturą banku 12

6.2 Wzorzec 13

6.3 Procedura przekazania pojedynczego modelu 13

6.4 Weryfikacja poprawności integracji 14

6.5 Przekazane modele 14

6.6 Status przekazania i uruchomienia 18

7 Wyniki **20**

7.1 EUR/PLN 20

7.1.1 Zakres przetestowanych modeli 20

7.1.2 Wykresy 21

7.1.3 Wnioski 22

7.2 USD/PLN 23

7.2.1 Zakres przetestowanych modeli 23

7.2.2 Wykresy 24

7.2.3 Wnioski 24

7.3 Stopa procentowa 25

7.3.1 Zakres przetestowanych modeli 25

7.3.2 Wykresy . . . 26
7.3.3 Wnioski . . . 27
7.4 Obligacje i krzywa rentowności . . . 27
7.4.1 Zakres i przygotowanie danych . . . 28
7.4.2 Estymacja krzywej dochodowości . . . 28
7.4.3 Prognozowanie czynników DNS . . . 28
7.4.4 Walidacja prognoz . . . 29
7.4.5 Główne wyniki . . . 29
7.4.6 Wyniki według terminu zapadalności . . . 29
7.4.7 Walidacja statystyczna . . . 29
7.4.8 Diagnostyka błędów i ograniczenia . . . 30
7.5 WIG20 . . . 31
7.5.1 Zakres przetestowanych modeli . . . 31
7.5.2 Wykresy . . . 32
7.5.3 Wnioski . . . 33
7.6 Ropa . . . 33
7.6.1 Zakres przetestowanych modeli . . . 33
7.6.2 Wykresy . . . 35
7.6.3 Wnioski . . . 36
7.7 Złoto . . . 36
7.7.1 Zakres przetestowanych modeli . . . 36
7.7.2 Wykresy . . . 37
7.7.3 Wnioski . . . 38
7.8 BTC . . . 38
7.8.1 Zakres przetestowanych modeli . . . 38
7.8.2 Wykresy . . . 39
7.8.3 Wnioski . . . 40
7.9 Podsumowanie wyników . . . 40

8 Podsumowanie realizacji zadania **42**

1 Podsumowanie zarządcze

Celem zadania 1.4 było przygotowanie i przeprowadzenie wstępnego procesu uczenia oraz kalibracji grupy modeli prognostycznych dla uzgodnionej grupy wskaźników, a następnie dostosowanie technicznie sprawnych implementacji do infrastruktury przygotowanej przez bank.

Prace objęły osiem grup wskaźników: kursy EUR/PLN i USD/PLN, stopę referencyjną NBP, krzywą rentowności obligacji skarbowych, indeks WIG20, ceny ropy Brent i złota oraz kurs BTC/USD. Dla poszczególnych wskaźników testowano modele ekonometryczne, modele uczenia maszynowego, sieci neuronowe, transformery, modele zmienności, modele klasyfikacyjne oraz modele czynnikowe krzywej rentowności.

Wstępne uczenie, kalibrację i porównanie konfiguracji przeprowadzono w lokalnym środowisku roboczym. Środowisko to służyło przygotowaniu modeli, kontroli poprawności implementacji oraz charakterystyce ich jakości prognostycznej. Nie stanowi ono przedmiotu przekazania. Przedmiotem przekazania są implementacje modeli dostosowane do interfejsów i sposobu dostarczania danych w infrastrukturze banku, wyniki testów potwierdzających ich działanie oraz dokumentacja pozwalająca zidentyfikować konfigurację i odtworzyć przebieg.

Łącznie oceniono 190 kombinacji modelu, wariantu danych, horyzontu oraz, w przypadku obligacji, tenoru. Pełny zestaw prognoz uzyskano dla 188 kombinacji. Wyjątkiem był model dekompozycyjny dla ropy, którego implementacja wymaga dalszego dopracowania. Wyniki prognostyczne mają charakter wstępny: modele oceniano przy ograniczonym zakresie kalibracji, bez systematycznej optymalizacji hiperparametrów i rozbudowanej selekcji predyktorów.

Najbardziej stabilną poprawę względem benchmarku uzyskano w prognozie zmienności przy wykorzystaniu modeli z rodziny GARCH. Przewagę odnotowano również dla części modeli kursów walut na horyzoncie 30 dni oraz dla większości modeli krzywej rentowności, szczególnie na jej krótkim końcu. W prognozowaniu poziomów cen instrumentów finansowych prognoza naiwna pozostała wymagającym punktem odniesienia, a wyniki wskazały kierunki dalszej kalibracji, w szczególności selekcję predyktorów, modelowanie stóp zwrotu i stabilizację prognoz wielokrokowych.

Odrębny i rozszerzony strumień prac dotyczył obligacji skarbowych. W przypadku pozostałych wskaźników punktem wyjścia był bezpośrednio obserwowany szereg zmiennej prognozowanej. W przypadku obligacji konieczne było najpierw zbudowanie samego obiektu prognozy, czyli dziennej krzywej dochodowości i opisujących ją czynników. Zakres ten obejmował przygotowanie i filtrację danych o instrumentach i przepływach pieniężnych, estymację dziennych krzywych Dynamic Nelson–Siegel, osobne prognozowanie czynników poziomu, nachylenia i krzywizny, rekonstrukcję przyszłej krzywej oraz ocenę wyników na rentownościach i cenach obligacji. Przeprowadzono również szeroki screening modeli i danych, walidację statystyczną oraz diagnostykę źródeł największych błędów. Modelowanie obligacji stanowiło tym samym rozszerzenie standardowego procesu zastosowanego dla pozostałych wskaźników i dostarczyło kompletnego rozwiązania analitycznego, od przygotowania danych o instrumentach do prognozy krzywej oraz wyceny obligacji.

Technicznie sprawne modele dostosowano do infrastruktury banku i poddano testom integracyjnym. Test obejmował odczyt danych, wykonanie treningu i predykcji, zapis wyników i logów oraz porównanie z przebiegiem referencyjnym. Ze względu na trwającą przebudowę backendu chmurowego pełna publikacja produkcyjna artefaktów nie była dostępna dla wszystkich modeli. Status zaliczenia oznacza zatem poprawne przejście testu integracyjnego w zakresie dostępnych komponentów infrastruktury, a nie akceptację modelu do zastosowania produkcyjnego.

2 Cel i zakres zadania

Celem zadania 1.4 było zbudowanie i przeprowadzenie wstępnego procesu uczenia i kalibracji grupy modeli uczenia maszynowego i sztucznej inteligencji dla pierwszej grupy wskaźników, zgodnie z priorytetami uzgodnionymi pomiędzy bankiem a zespołem SGH.

Zakres prac objął:

- przygotowanie danych do lokalnych eksperymentów prognostycznych;
- implementację reprezentatywnej grupy modeli ekonometrycznych, uczenia maszynowego i głębokiego uczenia;
- przeprowadzenie wstępnego uczenia i kalibracji modeli;
- ocenę modeli w chronologicznym protokole trening–walidacja–test i w backteście kroczącym;
- porównanie wyników z odpowiednimi benchmarkami;
- dostosowanie technicznie sprawnych modeli do wspólnego interfejsu infrastruktury banku;
- wykonanie testów potwierdzających poprawne uruchomienie i generowanie wyników;
- przygotowanie raportu z przeprowadzonych prac, uzyskanych wyników i zidentyfikowanych ograniczeń.

Lokalny potok eksperymentalny był narzędziem wykorzystywanym przez zespół SGH do uczenia, kalibracji, porównania konfiguracji i przygotowania wyników referencyjnych. Infrastruktura ta nie stanowi przedmiotu przekazania. Modele przekazywano w postaci kodu i konfiguracji dostosowanych do rejestru cech i modeli przygotowanego przez bank. Zakres zadania nie obejmował budowy infrastruktury bankowej, formalnego wyboru jednego finalnego modelu produkcyjnego, pełnej optymalizacji hiperparametrów ani wdrożenia produkcyjnego wszystkich modeli. Uruchomienie modelu w infrastrukturze banku potwierdza jego poprawność techniczną i zdolność do generowania wyników, lecz nie stanowi samoistnie rekomendacji do wykorzystania biznesowego.

Zakres modelowania obligacji został rozszerzony względem standardowego schematu prac przyjętego dla pozostałych wskaźników. W przypadku kursów walutowych, indeksów, surowców, stopy procentowej i BTC modele budowano dla wcześniej zdefiniowanego szeregu docelowego. W przypadku obligacji konieczne było dodatkowo przygotowanie danych o instrumentach i przepływach pieniężnych, oszacowanie dziennej krzywej dochodowości oraz utworzenie szeregów czynników stanowiących zmienne docelowe dla modeli prognostycznych. Strumień obligacyjny obejmował zatem pełny proces od danych o instrumentach, przez estymację i prognozowanie czynników Dynamic Nelson–Siegel, do rekonstrukcji przyszłej krzywej i wyceny obligacji. Z uwagi na szerszy zakres analityczny i metodologiczny wyniki tego strumienia przedstawiono w raporcie w bardziej szczegółowej formie.

3 Zakres wskaźników i modeli

Prace objęły osiem grup wskaźników reprezentujących kursy walutowe, stopy procentowe, krzywą rentowności, rynek akcji, rynki surowcowe oraz rynek kryptoaktywów. Dobór rodzin modeli zależał od charakteru szeregu i typu zadania prognostycznego.

Dla modeli poziomu badano co do zasady dwa warianty: wykorzystujący wyłącznie historię zmiennej prognozowanej oraz wariant rozszerzony o dodatkowe predyktory.

Tabela 1: Wskaźniki i rodziny modeli

Wskaźnik	**Rodziny modeli**
EUR/PLN	Prognoza naiwna, ARIMA, VAR, BVAR, XGBoost, LSTM, TFT
USD/PLN	Prognoza naiwna, ARIMA, VAR, BVAR, XGBoost, LSTM, TFT
Stopa procentowa	Prognoza naiwna, ARIMA, VAR, BVAR, logit, probit, ordered logit, ordered probit
Obligacje	AR(1), VAR, Diebold–Li, Ridge, las losowy, Extra Trees oraz modele łączące prognozy czynników DNS
WIG20	Prognoza naiwna, ARIMA, XGBoost, GARCH, EGARCH, GJR-GARCH
Ropa Brent	Prognoza naiwna, ARIMA, SVR, XGBoost, LSTM, VMD + XGBoost, GARCH, EGARCH, GJR-GARCH, GARCH-MIDAS
Złoto	Prognoza naiwna, ARIMA, XGBoost, LSTM, GARCH, EGARCH, GJR-GARCH
BTC/USD	Prognoza naiwna, SVR, XGBoost, LSTM, TFT, PatchTST oraz walidacyjnie Helformer

Modele zmienności oceniano oddzielnie od modeli poziomu, natomiast dla stopy procentowej obok prognozy poziomu analizowano także kierunek przyszłej decyzji.

Szczegółowy opis danych, horyzontów, protokołu testowego i wyników przedstawiono w kolejnych rozdziałach.

4 Dane

Eksperymenty lokalne objęły osiem wskaźników (targetów) i trzy typy zadań prognostycznych: prognozę poziomu (wszystkie wskaźniki), prognozę zmienności (WIG20, ropa, złoto) oraz prognozę kierunku decyzji o stopie procentowej. W tym rozdziale opisano źródła danych, zakres i częstotliwość szeregów, zestawy predyktorów oraz zasady przygotowania danych wspólne dla wszystkich eksperymentów.

Pliki źródłowe wykorzystywano wyłącznie do odczytu. Wszystkie operacje na danych – wyrównanie kalendarzy, uwzględnienie opóźnień publikacji, wyliczenie zmiennych pochodnych (np. logarytmicznych stóp zwrotu, różnic stóp procentowych) – wykonuje mechanizm uruchomieniowy na podstawie jawnych specyfikacji danych zapisanych w plikach konfiguracyjnych YAML. Dzięki temu każdy wynik jest jednoznacznie powiązany z wersją danych i może zostać odtworzony.

4.1 Źródła danych

Wykorzystano sześć zbiorów danych, przygotowanych w kolejnych etapach prac:

- **Kursy średnie NBP** (tabela A) dla EUR/PLN i USD/PLN, pobrane z interfejsu API NBP, obejmujące fixingi od 2.01.2002 do 16.09.2026 (6242 notowania).
- **Wspólna tablica dzienna dla kursów walut i WIG20**, zawierająca 25 zmiennych w siatce dni kalendarzowych od 2.01.2002 do 17.09.2026: kursy NBP, notowania WIG20 (otwarcie, maksimum, minimum, zamknięcie, wolumen), rentowności i stopy procentowe w Polsce i USA, indeksy S&P 500 i VIX, cenę ropy WTI oraz wybrane dane makroekonomiczne o częstotliwości miesięcznej i kwartalnej. Wartości przeniesiono 1:1 ze źródeł, bez

uzupełniania braków; zgodność każdej kolumny ze źródłem zweryfikowano po zapisie.

- **Eksport danych rynkowych z 5.10.2026** (25 kolumn, dni kalendarzowe od 1.01.2000 do 1.09.2026): ceny ropy Brent i złota, indeks dolara DXY, kurs EUR/USD EBC, indeksy S&P 500, NASDAQ-100 i VIX, stopy Fed Funds, stopy NBP i EBC. Zbiór ten był podstawą eksperymentów dla ropy i złota.
- **Eksport danych z 13.09.2026**, obejmujący m.in. notowania BTC/USD wraz ze zmiennymi rynkowymi; dane kończą się 31.03.2025. Był to jedyny dostępny zbiór z notowaniami BTC, dlatego wykorzystano go w eksperymentach dla tego wskaźnika.
- **Dane uzupełnione ze źródeł publicznych** (NBP, CEIC, investing.com): dzienny szereg stopy referencyjnej NBP (26.02.1998–16.09.2026), miesięczny panel stopy procentowej (stopa referencyjna, WIBOR 3M, inflacja CPI r/r, miesięczna zmiana kursu EUR/PLN; 02.2002–06.2026) oraz krzywa rentowności obligacji skarbowych.
- **Panel badawczy krzywej rentowności** (29.11.2004–28.08.2026), zawierający czynniki dynamicznego modelu Nelsona–Siegela (DNS: poziom, nachylenie, krzywizna) wraz z ich opóźnieniami i przyrostami, stopę referencyjną NBP, stawkę POLONIA, stopę MRO EBC i kurs EUR/PLN.

4.2 Charakterystyka danych według wskaźników

Tabela 2 zestawia dane wykorzystane we wszystkich eksperymentach: częstotliwość i zakres szeregu prognozowanego, główne predyktory używane w wariancie „target i predyktory" oraz istotne ograniczenia. Wariant „tylko target" korzysta wyłącznie z historii prognozowanego szeregu.

Tabela 2: Charakterystyka danych we wszystkich eksperymentach

Target	Częstotliwość	Zakres danych	Główne predyktory	Braki / ograniczenia
EUR/PLN (poziom)	dzienna, fixingi NBP	02.01.2002–16.09.2026	Modele ML: zmiana EUR/USD (NBP), VIX, stopa zwrotu S&P 500, rentowność PL 10Y, różnica rentowności PL–US 10Y, różnica WIBOR 3M – Fed Funds, stopa referencyjna NBP, CPI PL r/r. VAR i BVAR: kurs USD/PLN i cena ropy WTI.	Serie rynkowe z USA i cena WTI kończą się w maju 2026 r.; w 2 z 31 momentów testowych modele korzystały z ostatniej dostępnej wartości. Brak w danych stóp procentowych i inflacji strefy euro.
USD/PLN (poziom)	dzienna, fixingi NBP	02.01.2002–16.09.2026	Modele ML: zmiana EUR/PLN, zmiana EUR/USD (NBP), rentowność UST 10Y, spread UST 10Y–2Y, różnica WIBOR 3M – Fed Funds, różnica rentowności PL–US 10Y, VIX, stopa zwrotu S&P 500, różnica inflacji USA–Polska. VAR i BVAR: kurs EUR/PLN i cena ropy WTI.	Jak dla EUR/PLN. Kurs EUR/USD EBC (publikowany po fixingu NBP) zastąpiono kursem implikowanym z tabeli NBP, aby uniknąć wykorzystania informacji niedostępnej w momencie prognozy.

Target	Częstotliwość	Zakres danych	Główne predyktory	Braki / ograniczenia
WIG20 (poziom i zmienność)	dzienna, sesje GPW	04.01.2010–17.09.2026	Stopa zwrotu S&P 500, VIX, zmiany kursów EUR/PLN i USD/PLN, różnica rentowności PL–US 10Y, WIBOR 3M, CPI PL r/r. Modele zmienności: tylko target.	Krótsza historia (od 2010 r.). Serie z USA kończą się w maju 2026 r., co dotyczy 57 z 599 momentów testowych.
Ropa Brent (poziom i zmienność)	dzienna, sesje ICE	30.07.2007–01.09.2026	Zmiana EUR/USD (EBC), zmiana DXY, stopa zwrotu S&P 500, VIX, stopa Fed Funds (dzienna). GARCH-MIDAS: średnia miesięczna stopy Fed Funds.	Luka w notowaniach w IV 2009 r. (ok. 12 sesji). W eksporcie brak ceny WTI, dlatego targetem jest Brent. Brak danych o zapasach ropy i indeksu zmienności OVX.
Złoto (poziom i zmienność)	dzienna, sesje COMEX	30.08.2000–01.09.2026	Zmiana EUR/USD (EBC), zmiana DXY, stopa zwrotu S&P 500, VIX, stopa Fed Funds (dzienna). Modele zmienności: tylko target.	Szereg notowań kontraktu terminowego połączony z dwóch źródeł (punkt połączenia 29.05.2020, w zbiorze treningowym). Brak rentowności UST 10Y w eksporcie.
BTC/USD (poziom)	dzienna, 7 dni w tygodniu	17.09.2014–31.03.2025	Stopa zwrotu S&P 500, VIX, zmiana DXY, rentowność UST 10Y, stopa zwrotu złota (wszystkie z opóźnieniem 1 dnia roboczego).	Dane kończą się 31.03.2025; okres testowy jest wcześniejszy niż dla pozostałych wskaźników.
Stopa ref. NBP (szereg dzienny)	dni robocze	26.02.1998–16.09.2026	Tylko target (prognoza naiwna i ARIMA).	Szereg schodkowy, zmieniający się rzadko; w latach 2020–2021 wartości bliskie zera.
Stopa ref. NBP (szereg miesięczny, kierunek decyzji)	miesięczna	02.2002–06.2026	Poziom: WIBOR 3M, CPI r/r. Kierunek: CPI r/r, różnica WIBOR 3M – stopa referencyjna, miesięczna zmiana EUR/PLN.	Predyktory bez opóźnień publikacji (jak w implementacji referencyjnej w R). Zbiór testowy obejmuje 17 momentów prognozy, w tym jedną zmianę stopy.
Obligacje (stopy zerokuponowe 1Y, 2Y, 5Y, 7Y, 10Y)	dzienna, dni notowań	29.11.2004–28.08.2026	Czynniki DNS (poziom, nachylenie, krzywizna) z opóźnieniami i przyrostami; w wariantach rozszerzonych także stopa NBP, POLONIA, stopa MRO EBC, kurs EUR/PLN i zmienne ryzyka.	Targetem jest stopa zerokuponowa odtworzona z modelu DNS, a nie notowania benchmarków. Rentowność 1Y w źródle bywa nieciągła.

Historię każdego wskaźnika podzielono chronologicznie na zbiór treningowy (70%), walidacyjny (15%) i testowy (15%), zgodnie z protokołem opisanym w rozdziale 5. Ponieważ zakresy dostępnych danych różnią się między wskaźnikami, różnią się także okresy poszczególnych zbiorów

(tabela 3). W obrębie jednego wskaźnika wszystkie modele, łącznie z benchmarkiem, oceniano na identycznych okresach i w tych samych momentach prognozy.

Tabela 3: Chronologiczny podział danych (70/15/15) i liczba momentów prognozy w zbiorze testowym

Target	Trening	n	Walidacja	n	Test	n	Momenty
EUR/PLN, USD/PLN	02.01.2002–12.04.2019	4369	15.04.2019–27.12.2022	936	28.12.2022–16.09.2026	937	31
WIG20	04.01.2010–13.09.2021	2924	14.09.2021–11.03.2024	626	12.03.2024–17.09.2026	628	599
Ropa Brent	30.07.2007–30.12.2020	3326	31.12.2020–30.10.2023	712	31.10.2023–01.09.2026	714	685
Złoto	30.08.2000–16.11.2018	4568	19.11.2018–07.10.2022	978	10.10.2022–01.09.2026	980	951
BTC/USD	17.09.2014–31.01.2022	2694	01.02.2022–31.08.2023	577	01.09.2023–31.03.2025	578	549
Stopa NBP (dzienna)	26.02.1998–21.02.2018	5214	22.02.2018–03.06.2022	1117	06.06.2022–16.09.2026	1118	55
Stopa NBP (mies.)	01.02.2002–01.02.2019	205	01.03.2019–01.09.2022	43	01.10.2022–01.06.2026	45	17
Obligacje (DNS)	29.11.2004–19.02.2020	3805	20.02.2020–22.05.2023	815	23.05.2023–28.08.2026	817	19

n – liczba obserwacji w siatce czasu targetu (dni notowań; dni kalendarzowe dla BTC, dni robocze dla szeregu dziennego stopy, miesiące dla szeregu miesięcznego stopy). Momenty – liczba momentów prognozy w zbiorze testowym. Podział dla szeregu miesięcznego stopy dotyczy także prognozy kierunku decyzji, a dla obligacji – wszystkich tenorów.

4.3 Zasady przygotowania danych

Dla każdego wskaźnika zdefiniowano moment prognozy, czyli chwilę, w której model wyznacza prognozę. Dla kursów walut jest to fixing NBP (ok. 11:00), dla WIG20 – zamknięcie sesji GPW, dla ropy Brent i złota – rozliczenie notowań odpowiednio na giełdach ICE i COMEX, a dla BTC – dzienne zamknięcie notowań. Względem momentu prognozy każdej zmiennej przypisano opóźnienie publikacji:

- notowania z rynków zamykanych po momencie prognozy (np. zamknięcia rynku amerykańskiego dla kursów walut i WIG20) są dostępne z opóźnieniem jednego dnia roboczego;
- dane miesięczne i kwartalne, datowane końcem okresu, są dostępne z opóźnieniem odpowiadającym terminom ich publikacji (np. 15 dni dla inflacji CPI w Polsce, 32 dni dla średniej miesięcznej stopy Fed Funds);
- w momencie prognozy model otrzymuje ostatnią znaną wartość każdej zmiennej, bez interpolacji i bez wartości z przyszłości.

Zmienne o różnych kalendarzach (dni robocze w Polsce, sesje w USA, notowania 7 dni w tygodniu, dane miesięczne) wyrównywano do siatki czasu targetu według tej samej zasady ostatniej znanej wartości. Stopy procentowe NBP, zapisane w źródłach tylko w dniach zmiany, przenoszono w przód do kolejnej zmiany. Zmienne potencjalnie zawierające informację o samym targecie (np. nachylenie krzywej obliczane z prognozowanego tenoru) oznaczono w specyfikacjach jako niedozwolone w roli predyktorów.

4.4 Kontrola jakości danych i doświadczenia z pracy na danych

Dane do projektu pochodziły z kilku równoległych ścieżek i były udostępniane w kolejnych wersjach, w miarę jak doprecyzowywano zakres zmiennych dla poszczególnych wskaźników. Taki tryb pracy jest naturalny w projektach badawczo-wdrożeniowych, w których wymagania wobec danych krystalizują się równolegle z budową modeli. Wymagał on jednak wprowadzenia stałej warstwy kontroli: przed użyciem w modelach każdy zbiór był przeglądany pod kątem zgodności zawartości z opisem kolumn, ciągłości siatki dat, luk, wartości skrajnych oraz ryzyka wykorzystania informacji niedostępnej w momencie prognozy. Kluczowe serie porównywano z niezależnymi źródłami.

Przeglądy potwierdziły wysoką jakość podstawowych szeregów – na przykład kursy EUR/PLN i USD/PLN w eksporcie są w pełni zgodne z danymi API NBP (6231 z 6231 dni), a skrajne zmiany notowań odpowiadają znanym zdarzeniom rynkowym. Jednocześnie pozwoliły one wcześnie zidentyfikować kwestie, które przy automatycznym wykorzystaniu danych mogłyby zniekształcić wyniki modeli:

- **opis i zawartość kolumn** – w pierwszej wersji eksportu kilka kolumn miało nazwy nieodpowiadające zawartości (np. indeks efektywnego kursu złotego opisany jako rentowność obligacji 10-letnich); kwestie te zostały skorygowane w kolejnej wersji eksportu, a do czasu korekty stosowano słownik zgodności nazw;
- **łączenie serii z różnych źródeł** – szereg cen złota jest połączeniem dwóch serii notowań; punkt połączenia oznaczono i uwzględniono w interpretacji wyników;
- **datowanie danych okresowych** – część danych miesięcznych jest datowana początkiem okresu, którego dotyczy, mimo że ich wartość jest znana dopiero po jego zakończeniu. Co do zasady ryzyko wykorzystania informacji niedostępnej w momencie prognozy ograniczano przez odpowiednie opóźnienia publikacji. Wyjątkiem były modele oparte na miesięcznym panelu stopy procentowej, w których predyktory, w tym inflację CPI, wykorzystano bez uwzględnienia opóźnienia publikacji, zgodnie z implementacją referencyjną. Wyniki tych modeli mają charakter wstępny i wymagają ostrożności interpretacyjnej;
- **różne horyzonty dostępności** – poszczególne zbiory kończą się w różnych datach (od 31.03.2025 dla BTC do 17.09.2026 dla WIG20), co przekłada się na różne okresy testowe; w przypadku predyktorów kończących się wcześniej niż target modele korzystały z ostatniej dostępnej wartości, a liczbę takich momentów prognozy raportowano;
- **zmiany zakresu między wersjami** – kolejne wersje eksportu różniły się zestawem kolumn i źródłem niektórych serii (np. kursu EUR/USD), dlatego nie łączono kolumn pochodzących z różnych wersji.

Wszystkie zidentyfikowane kwestie udokumentowano, a sposób ich obsługi zapisano jawnie w specyfikacjach danych, bez modyfikowania plików źródłowych. Doświadczenia te zostaną wykorzystane w kolejnym etapie projektu, w którym zasilanie modeli danymi ma zostać ujednolicone w oparciu o rejestr cech w infrastrukturze banku (rozdział 6), zapewniający wersjonowanie zmiennych i wyrównanie danych według stanu wiedzy w momencie prognozy.

5 Wstępne uczenie, kalibracja i testy lokalne

5.1 Sposób prowadzenia testów

Wszystkie modele w projekcie, niezależnie od wskaźnika i rodziny modeli, testowano lokalnie, poza infrastrukturą zamawiającego, według jednego wspólnego protokołu. Historię każdego wskaźnika podzielono chronologicznie na trzy rozłączne części: zbiór treningowy (najstarsze 70% obserwacji), walidacyjny (kolejne 15%) i testowy (najnowsze 15%). Podziału dokonano osobno dla każdego wskaźnika, na jego własnej siatce dat, więc okresy różnią się między wskaźnikami w zależności od dostępności i częstotliwości danych (tabela 3). W obrębie wskaźnika wszystkie modele, łącznie z benchmarkiem, oceniano na identycznych okresach i w identycznych momentach prognozy. Zbiór treningowy służy do estymacji, walidacyjny do wyboru konfiguracji, a testowy wyłącznie do oceny końcowej.

W zbiorze walidacyjnym i testowym zastosowano backtest kroczący (*walk-forward*) z oknem rozszerzającym. W każdym momencie prognozy t model jest budowany od nowa na wszystkich

obserwacjach dostępnych do t włącznie i wyznacza prognozy na zadany horyzont, po czym moment prognozy przesuwa się o stały krok. Dla każdego wskaźnika badano dwa horyzonty, krótki i średni, a krok backtestu dobrano do częstotliwości i długości szeregu (tabela 4). Ostatni moment prognozy w każdym zbiorze wyznaczono tak, aby mieścił się w nim dłuższy z horyzontów, dzięki czemu wszystkie horyzonty objęte konfiguracją oceniane są w tych samych momentach.

Tabela 4: Horyzonty prognozy i krok backtestu według wskaźników

Wskaźnik	Horyzonty	Krok backtestu
EUR/PLN, USD/PLN	1 i 30 dni notowań	30 obserwacji
Obligacje (stopy zerokuponowe DNS)	60 i 250 dni notowań	30 obserwacji
Stopa procentowa (szereg dzienny)	1 i 30 dni roboczych	20 obserwacji
Stopa procentowa (szereg miesięczny)	1 i 12 miesięcy	2 miesiące
WIG20, ropa, złoto	1 i 30 dni notowań	1 obserwacja
BTC	1 i 30 dni kalendarzowych	1 obserwacja

Prognozy wielokrokowe wyznaczano dynamicznie: prognoza na dany krok korzysta wyłącznie z informacji znanej w momencie t oraz z wcześniejszych prognoz modelu, a nie z wartości zrealizowanych w horyzoncie. Zmienne objaśniające, które nie są prognozowane przez sam model, utrzymywano w horyzoncie na wartościach znanych w momencie t. Modele z elementem losowym (sieci neuronowe, XGBoost i pokrewne) budowano od nowa w każdym momencie prognozy i dla każdego ziarna generatora.

Zapobieganie przeciekowi informacji z przyszłości opiera się na kilku regułach stosowanych jednolicie dla wszystkich wskaźników. Każdej zmiennej przypisano opóźnienie publikacji: wartość obserwowana w dniu d jest uznawana za znaną dopiero od dnia d powiększonego o to opóźnienie. Notowania z rynków zamykanych po momencie prognozy są dostępne z opóźnieniem jednego dnia roboczego, a dane miesięczne i kwartalne, datowane końcem okresu, z opóźnieniem odpowiadającym terminom ich publikacji. Wyjątkiem są modele oparte na miesięcznym panelu stopy procentowej (VAR, BVAR oraz modele kierunku decyzji), w których predyktory – w tym inflację CPI – wykorzystano bez uwzględnienia opóźnienia publikacji, zgodnie z implementacją referencyjną (podrozdział 7.3). W momencie prognozy t model otrzymuje ostatnią znaną wartość każdej zmiennej, bez interpolacji. Transformacje i skalowanie zmiennych wyznaczano wyłącznie na danych dostępnych w danym momencie prognozy, a wartości zrealizowane w horyzoncie służyły jedynie do obliczenia błędów.

5.2 Zakres kalibracji

Na obecnym etapie kalibracja miała charakter wstępny i służyła ustaleniu konfiguracji pozwalających sprawdzić poprawność działania modeli. Dla każdego modelu rozpatrywano niewielką, z góry ustaloną siatkę konfiguracji, w wariancie opartym wyłącznie na historii targetu, a tam, gdzie model na to pozwala, także w wariancie z predyktorami. Do oceny na zbiorze testowym przechodziła konfiguracja o najlepszym średnim wyniku miary głównej na zbiorze walidacyjnym. W zależności od rodziny siatka obejmowała rzędy i liczbę opóźnień modeli ekonometrycznych, parametry rozkładu a priori modeli bayesowskich, specyfikację modeli zmienności, a w modelach uczenia maszynowego długość okna wejściowego oraz parametry architektury i uczenia. Modele z elementem losowym uruchamiano dla trzech ziaren generatora liczb losowych, raportując średni wynik zamiast najlepszego pojedynczego uruchomienia. Systematyczny dobór hiperparametrów i zestawów predyktorów przewidziano na kolejne etapy projektu.

5.3 Benchmark i metryki

Dla modeli poziomu benchmarkiem była prognoza naiwna, zakładająca, że wartość wskaźnika w horyzoncie h będzie równa ostatniej znanej obserwacji:

$$\hat{y}_{T+h}^{\text{naiwna}} = y_T.$$

Główną miarą jakości prognoz poziomu był średni bezwzględny błąd procentowy, liczony na poziomie wskaźnika, osobno dla każdego horyzontu, ze wszystkich N momentów prognozy danego zbioru:

$$\text{MAPE}_h = \frac{100\%}{N} \sum_{i=1}^{N} \left| \frac{y_{t_i+h} - \hat{y}_{t_i+h|t_i}}{y_{t_i+h}} \right|.$$

Modele prognozujące zmianę lub stopę zwrotu oceniano po przeliczeniu prognozy na poziom wskaźnika. Pomocniczo obliczano średni błąd bezwzględny (MAE), pierwiastek błędu średniokwadratowego (RMSE) i trafność kierunku zmiany. Względną jakość modelu mierzono poprawą względem prognozy naiwnej:

$$\text{Poprawa} = \frac{\text{MAPE}_{\text{naiwna}} - \text{MAPE}_{\text{model}}}{\text{MAPE}_{\text{naiwna}}} \cdot 100\%,$$

przy czym wartość dodatnia oznacza model dokładniejszy od benchmarku. Dla poziomu stopy procentowej, która przez długie okresy pozostaje niezmieniona, a w części próby przyjmuje wartości bliskie zera, MAPE jest miarą niestabilną, dlatego w tym przypadku główną miarą jest MAE.

Modele zmienności (rodzina GARCH) prognozują zmienność warunkową stóp zwrotu, dlatego oceniano je osobno, względem zmienności zrealizowanej mierzonej kwadratem logarytmicznej stopy zwrotu. Miarą główną był MAE, pomocniczą RMSE, a benchmarkiem zmienność historyczna, czyli średnia kwadratów pięciu ostatnich stóp zwrotu.

Modele klasyfikacyjne, prognozujące kierunek decyzji o stopie procentowej (obniżka, brak zmiany, podwyżka), oceniano za pomocą Balanced Accuracy, Macro-F1 i macierzy pomyłek, z benchmarkiem w postaci prognozy braku zmiany. Balanced Accuracy jest średnią czułością w poszczególnych klasach, więc nie premiuje modelu, który stale wskazuje najczęstszą klasę.

Dla modeli z elementem losowym raportowano średnią i rozrzut wyników z trzech ziaren generatora.

Wyniki lokalne służyły do potwierdzenia poprawności technicznej, wstępnej kalibracji oraz charakterystyki prognostycznej modeli. Nie służyły do formalnego wyboru jednego modelu produkcyjnego.

5.4 Charakter etapu i interpretacja wyników

Przedmiotem zadania 1.4 było zbudowanie potoku modeli, ich implementacja, wstępne uczenie oraz potwierdzenie poprawności działania w jednolitym, odtwarzalnym protokole oceny. Kryterium powodzenia na tym etapie jest więc kompletność i poprawność przebiegu: model odczytuje dane zgodnie ze specyfikacją, nie korzysta z informacji z przyszłości, generuje pełny zestaw prognoz dla wszystkich horyzontów i daje wyniki porównywalne z benchmarkiem w tych samych momentach prognozy.

Dokładność prognoz uzyskana przy wstępnej kalibracji nie jest miarą docelowych możliwości modeli. W części przypadków MAPE modelu jest wyższe od MAPE prognozy naiwnej, co oznacza ujemną poprawę względem benchmarku. Jest to wynik oczekiwany na tym etapie: prognoza

naiwna jest wymagającym punktem odniesienia dla szeregów finansowych o charakterze zbliżonym do błądzenia losowego, a modele oceniano w konfiguracjach wybranych z niewielkiej siatki, bez systematycznego strojenia hiperparametrów i bez selekcji predyktorów. Systematyczny dobór parametrów, selekcja i rozszerzanie zestawów danych oraz uczenie modeli ukierunkowane na poprawę względem benchmarku stanowią przedmiot kolejnych etapów projektu. Wyniki przedstawione w rozdziale 7 należy zatem traktować jako punkt odniesienia (*baseline*) dla dalszych prac.

6 Przekazanie i uruchomienie modeli w infrastrukturze banku

Wstępne uczenie, kalibrację i testy modeli przeprowadzono w lokalnym środowisku roboczym zespołu SGH. Następnie technicznie sprawne implementacje dostosowano do sposobu dostarczania danych i uruchamiania modeli w infrastrukturze przygotowanej przez bank – rejestrze cech i modeli PKO Feature Registry (narzędzie `pko-fr`), w którym dane pochodzą z BigQuery (warstwy Silver i Gold projektu `lab-biz-tai-gcp-pr`), a procesy treningu, predykcji i walidacji są wykonywane przez bibliotekę banku, nie przez kod zespołu SGH. Dla każdego przekazywanego modelu przygotowano kod (klasę `Model` w `src/model.py`), konfigurację (`model_config.yaml`), wskazanie wersji cech i targetu oraz wynik referencyjny z przebiegu lokalnego. Poprawność integracji potwierdzano przez uruchomienie modelu w środowisku banku, wygenerowanie prognoz oraz porównanie rezultatu z przebiegiem lokalnym w przyjętej tolerancji.

6.1 Różnica między środowiskiem lokalnym a infrastrukturą banku

Środowisko lokalne służyło eksploracji: dane w plikach (parquet/CSV), własny silnik oceny (podział 70/15/15, backtest kroczący z oknem rozszerzającym, MAPE liczone dla każdego horyzontu względem modelu naiwnego), swoboda w doborze bibliotek i konfiguracji. Infrastruktura banku narzuca natomiast ustandaryzowany cykl życia modelu, w którym zespół SGH dostarcza wyłącznie klasę modelu, a całą resztę – pobranie i wyrównanie danych, walidację braków, podział walk-forward, liczenie metryk, serializację artefaktu – realizuje zamrożona biblioteka banku. Taka separacja gwarantuje, że wszystkie modele są oceniane identyczną procedurą i są porównywalne między sobą 1:1, niezależnie od autora i technologii.

Najważniejsze konsekwencje tej separacji dla przekazania:

- **Dane nie są plikiem, lecz cechą w rejestrze.** Każda zmienna objaśniająca (x) musi istnieć w rejestrze cech (*feature store*) jako zdefiniowana w SQL, wersjonowana cecha. Zmienne, których nie było w rejestrze, zakładano ścieżką `raw` → `template` → `add` → `compute`. Cechy makroekonomiczne i rzadsze niż dzienne pozostają w rejestrze w swojej naturalnej częstotliwości; ich dopasowanie do dziennego kalendarza targetu wykonuje złączenie *as-of* (*point-in-time*, bez podglądania przyszłości) na etapie eksportu macierzy treningowej.
- **Target to przyszły poziom serii.** Target definiuje się jako wskazaną serię bazową plus horyzont H; przesunięcie wartości o H dni wykonuje rejestr automatycznie. Dla każdego modelu i każdego horyzontu ($H = 1$ oraz $H = 30$) rejestrowano osobny target.
- **Ocena to walk-forward, nie pojedynczy podział.** Podstawą akceptacji jest walidacja krocząca metodą walk-forward (rosnące okno treningowe, test poza próbą), tożsama metodycznie z backtestem użytym lokalnie. Metryka celu jest zapisana na targecie i stamtąd wyprowadzana jednolicie przez wszystkie procesy.
- **Wymagany jest format ONNX.** Artefakt produkcyjny musi eksportować się do formatu

ONNX; predykcja na produkcji liczona jest lekko przez `onnxruntime`, bez bibliotek modelu. Format natywny (`pickle`) dopuszczano wyłącznie na fazę testów.

6.2 Wzorzec

Kluczowym wymaganiem integracyjnym, wspólnym dla wszystkich przekazywanych modeli, jest wzorzec narzucony przez standard banku: interfejs modelu operuje na poziomach (cena wchodzi i cena wychodzi), natomiast stacjonarną transformację (log-zwrot) model liczy wewnątrz siebie, względem kotwicy – kolumny z bieżącym poziomem prognozowanej serii, obecnej w zestawie cech. Dzięki temu modele zwrotowe i poziomowe dają wyjście w jednej przestrzeni i pozostają porównywalne. Rekonstrukcję poziomu dla modeli log-zwrotowych wpina się w sam graf ONNX, a nie w kod wokół niego – inaczej artefakt po eksporcie zwracałby zwrot zamiast poziomu i rozjechałby się z przebiegiem treningowym. Dostosowanie modeli zespołu SGH do tego wzorca było główną częścią pracy integracyjnej: modele budowane lokalnie na cechach i poziomie wprost wymagały przepisania tak, by kotwica znalazła się w zestawie cech, a rekonstrukcja poziomu była częścią grafu.

6.3 Procedura przekazania pojedynczego modelu

Dla każdego z przekazywanych modeli przechodzono tę samą, powtarzalną ścieżkę, zgodną z cyklem życia narzędzia `pko-fr`:

1. **Projekt modelu** (`init`) – utworzenie szkieletu katalogu modelu (`src/model.py`, `model_config.yaml`, `artifacts/`, `data/`) w ramach wspólnego środowiska projektu, wraz z wyborem najbliższego szablonu startowego (`lstm`, `arima`, `custom` itd.).
2. **Cechy w rejestrze cech** – dla każdej zmiennej objaśniającej sprawdzano, czy istnieje w rejestrze; brakujące zakładano (`raw` → `template` → `add` → `compute`), wraz z wariantami opóźnionymi (`--lag 1`) dla cech opóźnionych.
3. **Target** (`target_add`) – rejestracja targetu: seria bazowa (poziom prognozowanej ceny), horyzont (1 albo 30) oraz metryka oceny.
4. **Powiązanie cech z targetem** (`select` → `link`) – zdefiniowanie zestawu cech dla targetu w tabeli pomostowej. To wiąże dane z targetem, ale nie jest jeszcze wdrożeniem.
5. **Macierz treningowa** (`training_export`) – zbudowanie zbioru treningowego (parquet oraz manifest z wersjami cech, zakresem dat i skrótem danych dla odtwarzalności); narzędzie samo wpisuje listę cech do konfiguracji modelu i wyrównuje cechy rzadsze złączeniem *as-of*.
6. **Konfiguracja i kod** – uzupełnienie `model_config.yaml` (typ modelu, hiperparametry, ziarno, parametry walidacji) oraz implementacja klasy `Model` (`train`, `predict`, `to_onnx`, `explain`) z poprawnie wskazaną kotwicą.
7. **Walidacja walk-forward** (`model_validate`) – ocena modelu metodą kroczącą; raport zbiorczy (metryki dla każdego okna oraz agregaty) stanowił podstawę akceptacji i punkt odniesienia dla porównania z przebiegiem lokalnym.
8. **Trening finalny** (`model_train`) – wytrenowanie artefaktu produkcyjnego (`model.onnx` wraz z metadanymi) na pełnym zbiorze.

Krok publikacji (`model_publish`, wdrożenie artefaktu do GCS i rejestracja wersji) jest w infrastrukturze banku dostępny wyłącznie dla uruchomień chmurowych (`--backend gcp`). W okresie

realizacji prac backend chmurowy pozostawał w przebudowie (trwało przejście na Vertex Pipelines), przez co pełna publikacja produkcyjna nie była możliwa do wykonania od początku do końca. Przekazanie i weryfikację przeprowadzano zatem do etapu treningu i walidacji włącznie, a zgodność z przebiegiem lokalnym potwierdzano na wygenerowanych prognozach.

6.4 Weryfikacja poprawności integracji

Test działania uznawano za zaliczony, jeżeli model w infrastrukturze banku: (1) został poprawnie uruchomiony, (2) odczytał wymagane dane z rejestru cech, (3) wygenerował kompletny zestaw prognoz dla wszystkich horyzontów, (4) zapisał wyniki i logi oraz (5) uzyskał rezultat zgodny z przebiegiem lokalnym w przyjętej tolerancji. Zgodność oceniano przez porównanie prognoz i metryk agregatowych walk-forward uzyskanych w banku z wynikiem referencyjnym z przebiegu lokalnego na tym samym zakresie dat i przy tym samym protokole walidacji (liczba okien, minimalna frakcja treningowa, kolumna porządku czasu). Porównywano zarówno agregaty, jak i wynik pozycja po pozycji.

6.5 Przekazane modele

Przekazane modele zestawiono w tabeli 5. Modele poziomu realizują wzorzec „zwroty wewnątrz, poziomy na wejściu i wyjściu"; modele zmienności, modele kierunku decyzji NBP oraz modele krzywej rentowności stanowią osobne kategorie oceny, opisane w uwagach pod tabelą. Wiersze modeli o identycznej specyfikacji dla obu horyzontów połączono.

Tabela 5: Modele przekazane do infrastruktury banku

Identyfikator targetu	Model	Zmienna y (seria bazowa)	Zmienne x (cechy)
`ropa_svm_h1`, `ropa_svm_h30`	SVM/SVR	`OIL_BRENT_PRICE`	`OIL_BRENT_PRICE_LAG1`, `DXY_INDEX`, `EUR_USD_CURRENCY`, `GOLD_SPOT_PRICE`, `SPX_INDEX`
`ropa_lstm_h1`, `ropa_lstm_h30`	LSTM	`OIL_BRENT_PRICE`	`OIL_BRENT_PRICE_LAG1`, `DXY_INDEX`, `EUR_USD_CURRENCY`, `GOLD_SPOT_PRICE`, `SPX_INDEX`
`gold_xgboost_h1`, `gold_xgboost_h30`	XGBoost	`GOLD_SPOT_PRICE`	`GOLD_SPOT_PRICE_LAG1`, `DXY_INDEX`, `EUR_USD_CURRENCY`, `OIL_BRENT_PRICE`, `SPX_INDEX`, `VIX_PRICE`
`gold_garch_h1`, `gold_garch_h30`	GARCH	`GOLD_SPOT_PRICE`	`GOLD_SPOT_PRICE_LAG1`, `DXY_INDEX`, `EUR_USD_CURRENCY`, `OIL_BRENT_PRICE`, `SPX_INDEX`, `VIX_PRICE`
`btc_xgboost_h1`, `btc_xgboost_h30`	XGBoost	`BTC_USD_SPOT`	`BTC_USD_SPOT`, `BTC_USD_SPOT_LAG_1-20`, `US10Y`, `RISK_SCORE`
`btc_svm_h1`, `btc_svm_h30`	SVM/SVR	`BTC_USD_SPOT`	`BTC_USD_SPOT`, `BTC_USD_SPOT_LAG_1-5`, `US10Y`, `RISK_SCORE`
`btc_lstm_h1`, `btc_lstm_h30`	LSTM	`BTC_USD_SPOT`	`BTC_USD_SPOT`, `BTC_USD_SPOT_LAG_1-20`, `US10Y`, `RISK_SCORE`
`btc_tft_h1`, `btc_tft_h30`	TFT	`BTC_USD_SPOT`	`BTC_USD_SPOT`, `BTC_USD_SPOT_LAG_1-20`, `US10Y`, `RISK_SCORE`
`fx_eurpln_naive_h1`	Prognoza naiwna	EUR/PLN – kurs bieżący	Bieżący poziom EUR/PLN (`anchor_feature`)
`fx_eurpln_xgb_h30`	XGBoost	EUR/PLN – kurs bieżący	Bieżący EUR/PLN oraz 21 opóźnień (lag_01–lag_21)
`fx_usdpln_lstm_h1`	LSTM	USD/PLN – kurs bieżący	Bieżący USD/PLN oraz 20 opóźnień (lag_01–lag_20)
`fx_usdpln_tft_h30`	TFT	USD/PLN – kurs bieżący	Bieżący USD/PLN oraz 20 opóźnień (lag_01–lag_20)

Identyfikator targetu	Model	Zmienna y (seria bazowa)	Zmienne x (cechy)
eurpln_1d_naive	Naiwny	EUR_PLN_CURRENCY	EUR_PLN_CURRENCY
eurpln_1d_arima	ARIMA	EUR_PLN_CURRENCY	EUR_PLN_CURRENCY
eurpln_1d_var	VAR	EUR_PLN_CURRENCY	EUR_PLN_CURRENCY, OIL_BRENT_PRICE, USD_PLN_CURRENCY
eurpln_1d_bvar	BVAR	EUR_PLN_CURRENCY	EUR_PLN_CURRENCY, OIL_BRENT_PRICE, USD_PLN_CURRENCY
eurpln_30d_naive	Naiwny	EUR_PLN_CURRENCY	EUR_PLN_CURRENCY
eurpln_30d_arima	ARIMA	EUR_PLN_CURRENCY	EUR_PLN_CURRENCY
eurpln_30d_var	VAR	EUR_PLN_CURRENCY	EUR_PLN_CURRENCY, OIL_BRENT_PRICE, USD_PLN_CURRENCY
eurpln_30d_bvar	BVAR	EUR_PLN_CURRENCY	EUR_PLN_CURRENCY, OIL_BRENT_PRICE, USD_PLN_CURRENCY
usdpln_1d_naive	Naiwny	USD_PLN_CURRENCY	USD_PLN_CURRENCY
usdpln_1d_arima	ARIMA	USD_PLN_CURRENCY	USD_PLN_CURRENCY
usdpln_1d_var	VAR	USD_PLN_CURRENCY	USD_PLN_CURRENCY, EUR_PLN_CURRENCY, OIL_BRENT_PRICE
usdpln_1d_bvar	BVAR	USD_PLN_CURRENCY	USD_PLN_CURRENCY, EUR_PLN_CURRENCY, OIL_BRENT_PRICE
usdpln_30d_naive	Naiwny	USD_PLN_CURRENCY	USD_PLN_CURRENCY
usdpln_30d_arima	ARIMA	USD_PLN_CURRENCY	USD_PLN_CURRENCY
usdpln_30d_var	VAR	USD_PLN_CURRENCY	USD_PLN_CURRENCY, EUR_PLN_CURRENCY, OIL_BRENT_PRICE
usdpln_30d_bvar	BVAR	USD_PLN_CURRENCY	USD_PLN_CURRENCY, EUR_PLN_CURRENCY, OIL_BRENT_PRICE
stopa_d_1d_naive	Naiwny	NBP_RATE_REF	NBP_RATE_REF
stopa_d_1d_arima	ARIMA	NBP_RATE_REF	NBP_RATE_REF
stopa_d_30d_naive	Naiwny	NBP_RATE_REF	NBP_RATE_REF
stopa_d_30d_arima	ARIMA	NBP_RATE_REF	NBP_RATE_REF
stopa_m_1m_naive	Naiwny	NBP_RATE_REF	NBP_RATE_REF
stopa_m_1m_arima	ARIMA	NBP_RATE_REF	NBP_RATE_REF
stopa_m_1m_var	VAR	NBP_RATE_REF	NBP_RATE_REF, WIBOR_3M, CPI_POLAND_YOY
stopa_m_1m_bvar	BVAR	NBP_RATE_REF	NBP_RATE_REF, WIBOR_3M, CPI_POLAND_YOY
stopa_m_12m_naive	Naiwny	NBP_RATE_REF	NBP_RATE_REF
stopa_m_12m_arima	ARIMA	NBP_RATE_REF	NBP_RATE_REF
stopa_m_12m_var	VAR	NBP_RATE_REF	NBP_RATE_REF, WIBOR_3M, CPI_POLAND_YOY
stopa_m_12m_bvar	BVAR	NBP_RATE_REF	NBP_RATE_REF, WIBOR_3M, CPI_POLAND_YOY
stopa_kier_1m_logit	Logit	NBP_RATE_HIKE_M	NBP_RATE_HIKE_M, CPI_POLAND_YOY, WIBOR_3M, EUR_PLN_CHANGE_M
stopa_kier_1m_probit	Probit	NBP_RATE_HIKE_M	NBP_RATE_HIKE_M, CPI_POLAND_YOY, WIBOR_3M, EUR_PLN_CHANGE_M
stopa_kier_1m_ologit	Ordered logit	NBP_RATE_DECISION_M	NBP_RATE_DECISION_M, CPI_POLAND_YOY, WIBOR_3M, EUR_PLN_CHANGE_M
stopa_kier_1m_oprobit	Ordered probit	NBP_RATE_DECISION_M	NBP_RATE_DECISION_M, CPI_POLAND_YOY, WIBOR_3M, EUR_PLN_CHANGE_M
stopa_kier_12m_logit	Logit	NBP_RATE_HIKE_M	NBP_RATE_HIKE_M, CPI_POLAND_YOY, WIBOR_3M, EUR_PLN_CHANGE_M
stopa_kier_12m_probit	Probit	NBP_RATE_HIKE_M	NBP_RATE_HIKE_M, CPI_POLAND_YOY, WIBOR_3M, EUR_PLN_CHANGE_M
stopa_kier_12m_ologit	Ordered logit	NBP_RATE_DECISION_M	NBP_RATE_DECISION_M, CPI_POLAND_YOY, WIBOR_3M, EUR_PLN_CHANGE_M

Identyfikator targetu	Model	Zmienna y (seria bazowa)	Zmienne x (cechy)
stopa_kier_12m_oprobit	Ordered probit	NBP_RATE_DECISION_M	NBP_RATE_DECISION_M, CPI_POLAND_YOY, WIBOR_3M, EUR_PLN_CHANGE_M
Bonds_3y_h91	VAR+RIDGE	CURVE_DNS_BETA0_LEVEL, CURVE_DNS_BETA1_SLOPE, CURVE_DNS_BETA2_CURVATURE	YIELD_USA_10Y, YIELD_USA_10Y_LAG1, YIELD_DE_10Y, YIELD_DE_10Y_LAG1, EUR_PLN_CURRENCY, EUR_PLN_CURRENCY_LAG1, VIX_INDEX, VIX_INDEX_LAG1, OIL_BRENT_PRICE
Bonds_3y_h365	AR(1)+RIDGE	CURVE_DNS_BETA0_LEVEL, CURVE_DNS_BETA1_SLOPE, CURVE_DNS_BETA2_CURVATURE	NBP_RATE_REF, IRS_CURVE_POLAND_2Y, IRS_CURVE_POLAND_5Y, IRS_CURVE_POLAND_10Y, YIELD_USA_10Y, YIELD_DE_10Y, EUR_PLN_CURRENCY, VIX_INDEX
Bonds_5y_h91	VAR+RIDGE (IRS RISK FACTORS)	CURVE_DNS_BETA0_LEVEL, CURVE_DNS_BETA1_SLOPE, CURVE_DNS_BETA2_CURVATURE	NBP_RATE_REF, WIBOR_3M, FRA_1X4, FRA_3X6, FRA_6X9, FRA_6X9_LAG1, IRS_CURVE_POLAND_2Y, IRS_CURVE_POLAND_2Y_LAG1, IRS_CURVE_POLAND_5Y, IRS_CURVE_POLAND_10Y, GDP_POLAND_YOY_LAG1, CPI_POLAND_YOY_LAG1, RETAIL_SALES_POLAND_YOY_LAG1, INDUSTRIAL_PRODUCTION_POLAND_INDEX_LAG1, INDUSTRIAL_CONFIDENCE_POLAND_LAG1, WAGES_POLAND_LAG1
Bonds_5y_h365	VAR(1)	CURVE_DNS_BETA0_LEVEL, CURVE_DNS_BETA1_SLOPE, CURVE_DNS_BETA2_CURVATURE	CURVE_DNS_BETA0_LEVEL, CURVE_DNS_BETA1_SLOPE, CURVE_DNS_BETA2_CURVATURE, PL_BENCH_10Y_TTM_365D, PL_BENCH_2Y_TTM_365D, PL_BENCH_5Y_TTM_365D, PL_BENCH_7Y_TTM_365D
Bonds_6y_h91	RIDGE	CURVE_DNS_BETA0_LEVEL, CURVE_DNS_BETA1_SLOPE, CURVE_DNS_BETA2_CURVATURE	NBP_RATE_REF, WIBOR_3M, FRA_1X4, FRA_3X6, FRA_6X9, FRA_6X9_LAG1, IRS_CURVE_POLAND_2Y, IRS_CURVE_POLAND_2Y_LAG1, IRS_CURVE_POLAND_5Y, IRS_CURVE_POLAND_10Y, GDP_POLAND_YOY_LAG1, CPI_POLAND_YOY_LAG1, RETAIL_SALES_POLAND_YOY_LAG1, INDUSTRIAL_PRODUCTION_POLAND_INDEX_LAG1, INDUSTRIAL_CONFIDENCE_POLAND_LAG1, WAGES_POLAND_LAG1, YIELD_USA_10Y, YIELD_USA_10Y_LAG1, YIELD_DE_10Y, YIELD_DE_10Y_LAG1, EUR_PLN_CURRENCY, EUR_PLN_CURRENCY_LAG1, VIX_INDEX, VIX_INDEX_LAG1, OIL_BRENT_PRICE
Bonds_6y_h365	AR(1)	CURVE_DNS_BETA0_LEVEL, CURVE_DNS_BETA1_SLOPE, CURVE_DNS_BETA2_CURVATURE	CURVE_DNS_BETA0_LEVEL, CURVE_DNS_BETA1_SLOPE, CURVE_DNS_BETA2_CURVATURE, PL_BENCH_10Y_TTM_365D, PL_BENCH_2Y_TTM_365D, PL_BENCH_5Y_TTM_365D, PL_BENCH_7Y_TTM_365D

Uwagi do poszczególnych rodzin modeli, istotne dla integracji:

- **SVM/SVR (ropa).** Model regresji wektorów nośnych na cechach opóźnionych i rynkowych. Eksport do ONNX przez konwerter `skl2onnx`. Dostosowanie do wzorca banku wymagało przeniesienia rekonstrukcji poziomu do grafu i wskazania serii bazowej (poziomu) jako kotwicy w zestawie cech.
- **LSTM (ropa).** Sieć rekurencyjna realizująca log-zwrot wewnątrz i zwracająca poziom, z rekonstrukcją $P_t \cdot \exp(\hat{r})$ wpiętą w graf ONNX (eksport `torch.onnx`). Wykorzystano szablon `lstm` jako punkt startowy; dostosowano kotwicę i zestaw cech ropy.

- **XGBoost (złoto).** Model wzmacniania gradientowego na cechach. Eksport do ONNX przez `skl2onnx` lub konwerter dedykowany.
- **GARCH (złoto).** Model prognozuje zmienność warunkową, nie poziom ceny, więc stanowi osobną kategorię oceny. Biblioteka `arch` nie eksportuje się do ONNX, dlatego artefakt pozostaje w formacie natywnym – dopuszczalnym jedynie na fazę testów, a nie jako ścieżka produkcyjna. Model przekazano do weryfikacji działania, z zastrzeżeniem braku ścieżki wdrożeniowej w formacie natywnym.
- **XGBoost (bitcoin).** Model wzmacniania gradientowego na bieżącym poziomie BTC/USD, 20 opóźnieniach serii oraz zmiennych `US10Y` i `RISK_SCORE`. Bieżący poziom `BTC_USD_SPOT` jest obecny w zestawie cech i pełni rolę kotwicy: model uczy się log-zwrotu, a rekonstrukcja poziomu jest częścią grafu ONNX. Eksport do ONNX analogicznie jak w modelu XGBoost dla złota.
- **SVM/SVR (bitcoin).** Regresja wektorów nośnych w tym samym układzie co dla ropy (kotwica w zestawie cech, rekonstrukcja poziomu w grafie, eksport przez `skl2onnx`). W odróżnieniu od pozostałych modeli BTC korzysta z krótszego zestawu opóźnień (1–5 zamiast 1–20).
- **LSTM (bitcoin, USD/PLN).** Sieć rekurencyjna zbudowana z szablonu `lstm`, w tym samym wzorcu co LSTM dla ropy: log-zwrot wewnątrz, rekonstrukcja $P_t \cdot \exp(\hat{r})$ wpięta w graf (eksport `torch.onnx`). Opóźnienia serii (1–20) tworzą okno wejściowe sieci. Wariant BTC przekazano dla $H = 1$ i $H = 30$, wariant USD/PLN (`fx_usdpln_lstm_h1`) – dla $H = 1$.
- **TFT (bitcoin, USD/PLN).** Temporal Fusion Transformer realizujący ten sam wzorzec zwrotów wewnątrz i poziomów na wyjściu; eksport do ONNX przez `torch.onnx`, który wymaga ustalonej długości okna wejściowego i stałego układu cech. Wariant BTC przekazano dla $H = 1$ i $H = 30$, wariant USD/PLN (`fx_usdpln_tft_h30`) – dla $H = 30$.
- **Prognoza naiwna i XGBoost (EUR/PLN, modele `fx_eurpln`).** Model naiwny (`fx_eurpln_naive_h1`) zwraca bieżący poziom kursu wskazany jako kotwica (`anchor_feature`), więc jego graf ONNX sprowadza się do przekazania wejścia na wyjście. Model `fx_eurpln_xgb_h30` korzysta z bieżącego kursu i 21 opóźnień.
- **Modele naiwne (EUR/PLN, USD/PLN, stopa referencyjna NBP).** Prognozą jest ostatni znany poziom serii bazowej. Modele pełnią rolę punktu odniesienia, względem którego oceniane są pozostałe modele dla tych samych targetów, i nie wymagają dodatkowych cech poza samą serią.
- **ARIMA (EUR/PLN, USD/PLN, stopa referencyjna NBP).** Modele jednowymiarowe, korzystające wyłącznie z serii bazowej. Biblioteka `statsmodels` nie eksportuje się do ONNX; ponieważ prognoza ARIMA jest liniową funkcją przeszłych wartości i reszt, warunkiem ścieżki produkcyjnej jest odwzorowanie równania prognozy w grafie – w przeciwnym razie artefakt pozostaje w formacie natywnym, dopuszczalnym jedynie na fazę testów (jak w przypadku GARCH).
- **VAR i BVAR (EUR/PLN, USD/PLN).** Modele wielowymiarowe, w których seria bazowa jest modelowana łącznie z kursem drugiej pary walutowej i ceną ropy Brent. BVAR różni się od VAR rozkładem a priori, który ściąga parametry i stabilizuje oszacowania przy większej liczbie zmiennych. Prognoza na $H = 30$ powstaje przez iterację równań modelu; uwaga dotycząca eksportu do ONNX jest taka sama jak dla ARIMA.
- **Stopa referencyjna NBP – wariant dzienny (`stopa_d`).** Seria ma charakter schodkowy i zmienia się rzadko, dlatego dla horyzontów 1 i 30 dni przekazano wyłącznie model

naiwny i ARIMA; prognoza naiwna jest w tym przypadku wymagającym punktem odniesienia.

- **Stopa referencyjna NBP – wariant miesięczny (`stopa_m`).** Target zdefiniowany na serii miesięcznej z horyzontami 1 i 12 miesięcy. Modele VAR i BVAR rozszerzają serię bazową o `WIBOR_3M` i `CPI_POLAND_YOY`; cechy te są w rejestrze w swojej naturalnej częstotliwości i są dopasowywane do kalendarza targetu złączeniem *as-of*.
- **Logit i probit (kierunek decyzji NBP).** Modele klasyfikacji binarnej dla `NBP_RATE_HIKE_M`; zwracają prawdopodobieństwo zdarzenia, a nie poziom serii, więc – podobnie jak GARCH – stanowią osobną kategorię oceny, a wzorzec poziomów na wejściu i wyjściu nie ma do nich zastosowania. Graf sprowadza się do kombinacji liniowej cech i funkcji łączącej (logistycznej albo dystrybuanty rozkładu normalnego). Przekazano warianty dla horyzontu 1 i 12 miesięcy.
- **Ordered logit i ordered probit (kierunek decyzji NBP).** Modele dla uporządkowanych kategorii decyzji (`NBP_RATE_DECISION_M`), zwracające prawdopodobieństwa poszczególnych kategorii wyznaczane przez progi na wspólnym indeksie liniowym. Zestaw cech i kategoria oceny są takie same jak dla modeli binarnych; przekazano warianty dla horyzontu 1 i 12 miesięcy.
- **Modele obligacji (`Bonds_3y`, `Bonds_5y`, `Bonds_6y`).** Zmienną y są trzy czynniki dynamicznego modelu Nelsona–Siegela (poziom, nachylenie, krzywizna), więc target jest wielowymiarowy, a rentowność dla danego tenoru odtwarza się z prognozowanych czynników. Dla każdego tenoru przekazano osobny model dla horyzontu 91 i 365 dni: na krótszym horyzoncie modele VAR+Ridge i Ridge korzystają z szerokiego zestawu zmiennych rynkowych i makroekonomicznych (stopy, FRA, IRS, rentowności zagraniczne, kurs EUR/PLN, VIX, ropa), na dłuższym – modele AR(1), AR(1)+Ridge i VAR(1) opierają się na samych czynnikach i benchmarkach rentowności (`PL_BENCH_*_TTM_365D`) lub na węższym zestawie zmiennych. Komponent Ridge eksportuje się przez `skl2onnx`; część autoregresyjna jest liniowa i może zostać odwzorowana w grafie.

6.6 Status przekazania i uruchomienia

Status „zaliczony” oznacza poprawne wykonanie treningu i walidacji w ramach dostępnych komponentów infrastruktury banku oraz wygenerowanie wyników zgodnych z przebiegiem referencyjnym. Status ten nie oznacza publikacji produkcyjnego artefaktu, ponieważ backend publikacyjny GCP pozostawał w okresie realizacji zadania w przebudowie.

Tabela 6: Status przekazania i uruchomienia modeli

Target	Model	Horyzont	Test lokalny	Test integracyjny w infrastrukturze banku
Ropa (Brent)	SVM/SVR	1 i 30	zaliczony	zaliczony
Ropa (Brent)	LSTM	1 i 30	zaliczony	zaliczony
Złoto	XGBoost	1 i 30	zaliczony	zaliczony
Złoto	GARCH	1 i 30	zaliczony	zaliczony
Bitcoin (BTC/USD)	XGBoost	1 i 30	zaliczony	zaliczony
Bitcoin (BTC/USD)	SVM/SVR	1 i 30	zaliczony	zaliczony
Bitcoin (BTC/USD)	LSTM	1 i 30	zaliczony	zaliczony
Bitcoin (BTC/USD)	TFT	1 i 30	zaliczony	zaliczony
EUR/PLN	Prognoza naiwna	1	zaliczony	zaliczony

Target	Model	Horyzont	Test lokalny	Test integracyjny w infrastrukturze banku
EUR/PLN	XGBoost	30	zaliczony	zaliczony
USD/PLN	LSTM	1	zaliczony	zaliczony
USD/PLN	TFT	30	zaliczony	zaliczony
EUR/PLN	Naiwny	1 i 30	zaliczony	zaliczony
EUR/PLN	ARIMA	1 i 30	zaliczony	zaliczony
EUR/PLN	VAR	1 i 30	zaliczony	zaliczony
EUR/PLN	BVAR	1 i 30	zaliczony	zaliczony
USD/PLN	Naiwny	1 i 30	zaliczony	zaliczony
USD/PLN	ARIMA	1 i 30	zaliczony	zaliczony
USD/PLN	VAR	1 i 30	zaliczony	zaliczony
USD/PLN	BVAR	1 i 30	zaliczony	zaliczony
Stopa ref. NBP (dzienna)	Naiwny	1 i 30	zaliczony	zaliczony
Stopa ref. NBP (dzienna)	ARIMA	1 i 30	zaliczony	zaliczony
Stopa ref. NBP (miesięczna)	Naiwny	1 i 12 (mies.)	zaliczony	zaliczony
Stopa ref. NBP (miesięczna)	ARIMA	1 i 12 (mies.)	zaliczony	zaliczony
Stopa ref. NBP (miesięczna)	VAR	1 i 12 (mies.)	zaliczony	zaliczony
Stopa ref. NBP (miesięczna)	BVAR	1 i 12 (mies.)	zaliczony	zaliczony
Kierunek decyzji NBP	Logit	1 i 12 (mies.)	zaliczony	zaliczony
Kierunek decyzji NBP	Probit	1 i 12 (mies.)	zaliczony	zaliczony
Kierunek decyzji NBP	Ordered logit	1 i 12 (mies.)	zaliczony	zaliczony
Kierunek decyzji NBP	Ordered probit	1 i 12 (mies.)	zaliczony	zaliczony
Obligacje 3Y	VAR+RIDGE	91	zaliczony	zaliczony
Obligacje 3Y	AR(1)+RIDGE	365	zaliczony	zaliczony
Obligacje 5Y	VAR+RIDGE (IRS risk factors)	91	zaliczony	zaliczony
Obligacje 5Y	VAR(1)	365	zaliczony	zaliczony
Obligacje 6Y	RIDGE	91	zaliczony	zaliczony
Obligacje 6Y	AR(1)	365	zaliczony	zaliczony

Kryterium testu działania: model poprawnie uruchomiony w infrastrukturze banku, odczytał wymagane dane, wygenerował kompletny zestaw prognoz dla wszystkich horyzontów, zapisał wyniki i logi oraz uzyskał rezultat zgodny z przebiegiem lokalnym w przyjętej tolerancji.

7 Wyniki

Tabela 7: Targety

Target
EUR/PLN
USD/PLN
Stopa procentowa
Obligacje
WIG20
Ropa
Złoto
BTC

W rozdziale przedstawiono wyniki lokalnych testów wszystkich modeli dla ośmiu wskaźników. Dla każdego wskaźnika opisano zakres przetestowanych modeli wraz z wynikami na zbiorze testowym, a następnie zamieszczono do dwóch wykresów: zestawienie poprawy względem benchmarku dla obu horyzontów (linia zero oznacza wynik benchmarku, wartości dodatnie – przewagę modelu) oraz przykładową ścieżkę prognoz na dłuższym horyzoncie, porównaną z wartościami rzeczywistymi i prognozą naiwną. Model na wykresie ścieżki dobrano tak, aby ilustrował zachowanie charakterystyczne dla danej rodziny, a nie wyłącznie najlepszy wynik. Każdy podrozdział kończą wnioski.

Wyniki należy odczytywać zgodnie z charakterem obecnego etapu (podrozdział 5.4): służą one potwierdzeniu poprawności implementacji i protokołu oceny oraz wyznaczeniu punktu odniesienia dla dalszych prac. Wyniki gorsze od prognozy naiwnej nie świadczą o niepoprawności implementacji – wskazują obszary, w których kolejne etapy (dobór hiperparametrów, selekcja predyktorów, rozszerzenie danych) powinny przynieść największy przyrost jakości. Zestawienie zbiorcze dla wszystkich wskaźników zawiera podrozdział 7.9.

7.1 EUR/PLN

7.1.1 Zakres przetestowanych modeli

Dla kursu EUR/PLN przetestowano modele ekonometryczne oraz modele uczenia maszynowego i głębokiego uczenia, dla horyzontów 1 i 30 dni notowań. Punktem odniesienia była prognoza naiwna. Zbiór testowy obejmuje okres od 28.12.2022 do 16.09.2026 i 31 momentów prognozy (co 30 notowań).

- **ARIMA** – model jednowymiarowy z automatycznym doborem rzędów, oparty wyłącznie na historii kursu.
- **VAR i BVAR** – modele wielowymiarowe z dwoma opóźnieniami, w których kurs EUR/PLN modelowany jest łącznie z kursem USD/PLN i ceną ropy WTI; BVAR wykorzystuje rozkład a priori typu Minnesota, stabilizujący oszacowania parametrów.
- **XGBoost** – gradientowo wzmacniane drzewa decyzyjne na opóźnieniach i średnich kroczących kursu (oraz predyktorach w wariancie rozszerzonym).
- **LSTM** – rekurencyjna sieć neuronowa z oknem wejściowym 20–60 notowań.

- **TFT** (*Temporal Fusion Transformer*) – sieć z mechanizmem uwagi, z oknem wejściowym 20–40 notowań.

Modele uczenia maszynowego oceniano w wariancie „tylko target" i „target i predyktory" (zestaw predyktorów w tabeli 2); dla każdego wariantu wybierano jedną z czterech konfiguracji na podstawie zbioru walidacyjnego i uruchamiano ją dla trzech ziaren generatora. Modele ML prognozowały logarytmiczną stopę zwrotu (z wyjątkiem wybranego na walidacji wariantu LSTM z predyktorami, modelującego poziom kursu), a ocena odbywała się na poziomie kursu. Wszystkie modele wygenerowały prognozy we wszystkich momentach prognozy zbioru testowego. W dwóch ostatnich momentach (czerwiec i lipiec 2026 r.) modele VAR i BVAR korzystały z ostatniej dostępnej ceny ropy WTI (maj 2026 r.).

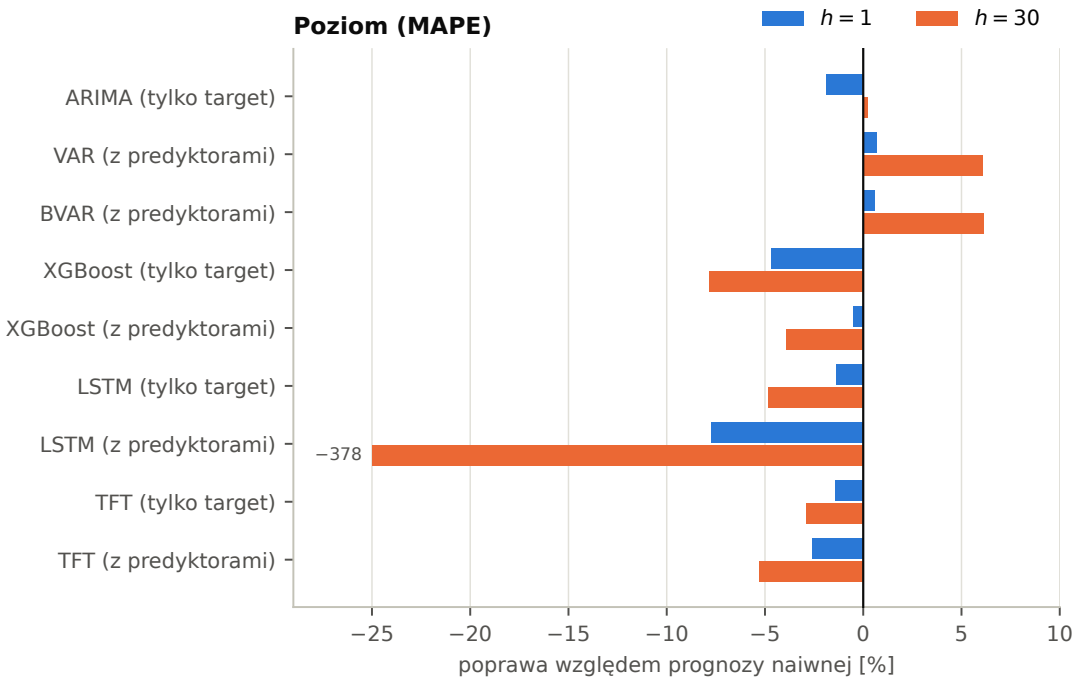
Tabela 8: EUR/PLN: MAPE na zbiorze testowym i poprawa względem prognozy naiwnej

		$h = 1$		$h = 30$	
Model	Wariant	MAPE [%]	Poprawa [%]	MAPE [%]	Poprawa [%]
Prognoza naiwna	ostatnia wartość	0,236		1,228	
ARIMA	tylko target	0,240	−1,9	1,225	0,2
VAR	target i predyktory	0,234	0,7	1,154	6,1
BVAR	target i predyktory	0,234	0,6	1,153	6,1
XGBoost	tylko target	0,247	−4,7	1,325	−7,8
XGBoost	target i predyktory	0,237	−0,5	1,276	−3,9
LSTM	tylko target	0,239 (0,002)	−1,4	1,288 (0,036)	−4,8
LSTM	target i predyktory	0,254 (0,006)	−7,7	5,874 (5,271)	−378,1
TFT	tylko target	0,239 (0,004)	−1,4	1,264 (0,011)	−2,9
TFT	target i predyktory	0,242 (0,003)	−2,6	1,294 (0,067)	−5,3

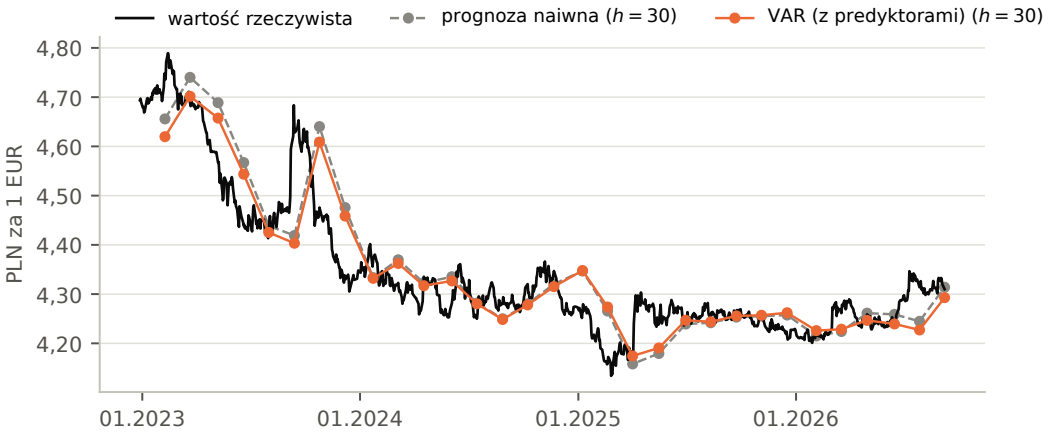
W nawiasie: odchylenie standardowe MAPE między trzema ziarnami generatora (modele z elementem losowym); brak nawiasu oznacza model deterministyczny lub identyczne wyniki dla wszystkich ziaren. Poprawa: względna zmiana MAPE wobec prognozy naiwnej; wartość dodatnia oznacza model dokładniejszy od benchmarku.

7.1.2 Wykresy

Rysunek 1 przedstawia poprawę MAPE względem prognozy naiwnej dla obu horyzontów, a rysunek 2 – prognozy modelu VAR na 30 dni notowań na tle wartości rzeczywistych i prognozy naiwnej.



Rysunek 1: EUR/PLN: poprawa MAPE względem prognozy naiwnej na zbiorze testowym (wartości poza skalą oznaczono liczbą)



Rysunek 2: EUR/PLN: prognozy na 30 dni notowań – model VAR i prognoza naiwna; punkty odpowiadają datom, na które wyznaczono prognozy w kolejnych momentach prognozy

7.1.3 Wnioski

Wszystkie modele przeszły pełną procedurę backtestu i wygenerowały komplet prognoz, co potwierdza poprawność ich implementacji i integracji z protokołem oceny. Na horyzoncie jednego dnia żaden model nie odbiega istotnie od prognozy naiwnej: najlepsze wyniki uzyskały modele VAR i BVAR (poprawa o 0,7% i 0,6%), a większość modeli uczenia maszynowego mieści się w przedziale do 5% gorszego MAPE. Jest to zgodne z charakterem dziennych zmian kursu walutowego, zbliżonym do błądzenia losowego. Na horyzoncie 30 dni wyraźnie wyróżniają się modele VAR i BVAR, uwzględniające kurs USD/PLN i cenę ropy, które obniżyły MAPE o 6,1% względem prognozy naiwnej; model ARIMA osiąga wynik zbliżony do benchmarku.

Predyktory pomagały przede wszystkim w modelach ekonometrycznych. W modelach uczenia maszynowego rozszerzenie zestawu zmiennych poprawiło wyniki XGBoost (np. na horyzoncie 30 dni z −7,8% do −3,9%), natomiast dla sieci LSTM i TFT wariant z predyktorami był słabszy niż wariant oparty wyłącznie na historii kursu. Szczególnie wyraźne jest to dla LSTM z predyktorami na horyzoncie 30 dni, gdzie jedno z trzech uruchomień dało znacznie wyższy błąd (MAPE 12,0% wobec 2,7–3,0% w pozostałych), co przekłada się na duży rozrzut między ziarnami. Pozostałe modele losowe były stabilne: odchylenie standardowe MAPE między ziarnami nie przekraczało 0,07 pkt proc., a XGBoost dawał identyczne wyniki dla wszystkich ziaren. Wyniki wskazują, że w kolejnym etapie dla sieci neuronowych priorytetem powinny być selekcja predyktorów i regularyzacja, a dla horyzontu 30 dni – rozwinięcie specyfikacji wielowymiarowych.

W infrastrukturze banku uruchomiono dla EUR/PLN modele naiwny, ARIMA, VAR i BVAR dla obu horyzontów oraz model XGBoost dla horyzontu 30 dni (rozdział 6).

7.2 USD/PLN

7.2.1 Zakres przetestowanych modeli

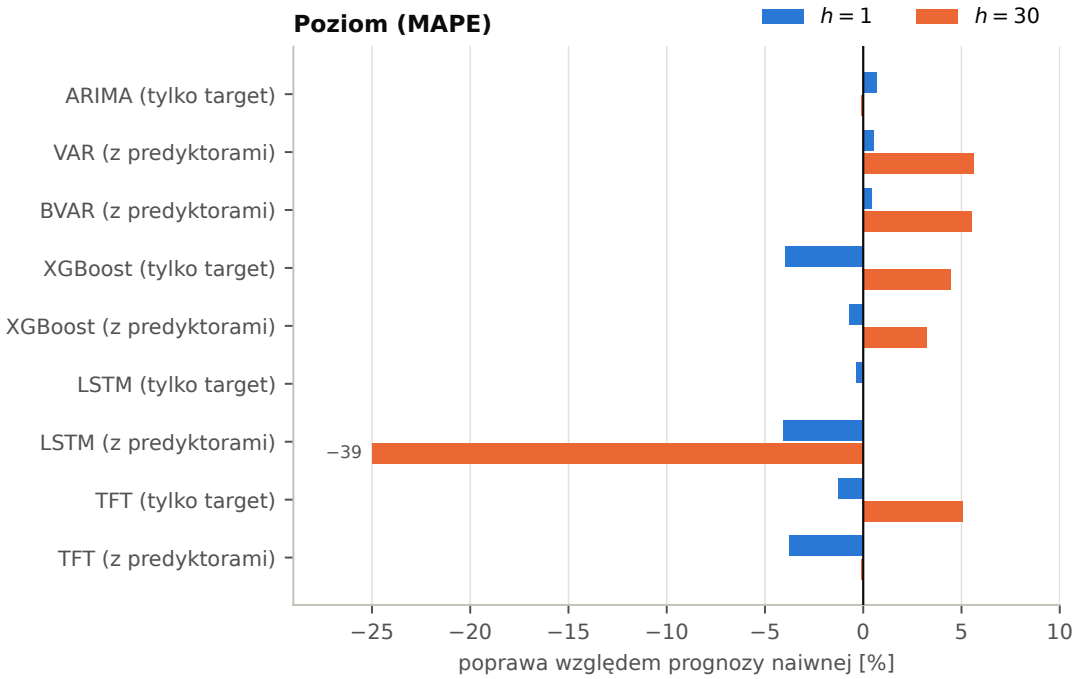
Dla kursu USD/PLN przetestowano ten sam zestaw modeli, na tych samych okresach i w tych samych momentach prognozy co dla EUR/PLN: prognozę naiwną, model ARIMA, modele VAR i BVAR (z kursem EUR/PLN i ceną ropy WTI) oraz modele XGBoost, LSTM i TFT w wariantach „tylko target" i „target i predyktory". Zestaw predyktorów modeli ML różni się od zestawu dla EUR/PLN i obejmuje m.in. zmianę kursu EUR/PLN, rentowności amerykańskie, dyferencjały stóp procentowych i różnicę inflacji USA–Polska (tabela 2). Wszystkie modele wygenerowały komplet prognoz.

Tabela 9: USD/PLN: MAPE na zbiorze testowym i poprawa względem prognozy naiwnej

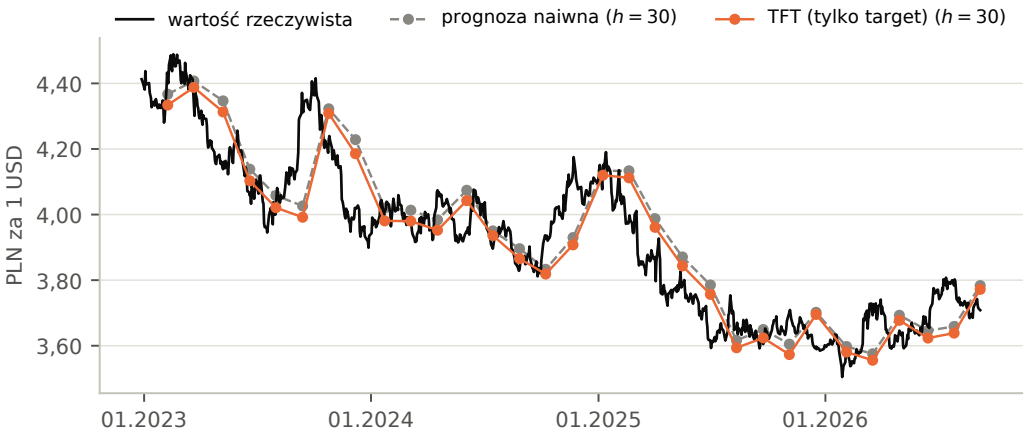
		$h = 1$		$h = 30$	
Model	Wariant	MAPE [%]	Poprawa [%]	MAPE [%]	Poprawa [%]
Prognoza naiwna	ostatnia wartość	0,463		2,357	
ARIMA	tylko target	0,460	0,7	2,360	−0,1
VAR	target i predyktory	0,461	0,5	2,225	5,6
BVAR	target i predyktory	0,461	0,4	2,227	5,5
XGBoost	tylko target	0,482	−4,0	2,253	4,5
XGBoost	target i predyktory	0,467	−0,7	2,281	3,2
LSTM	tylko target	0,465 (0,002)	−0,3	2,358 (0,002)	0,0
LSTM	target i predyktory	0,482 (0,004)	−4,1	3,272 (0,207)	−38,8
TFT	tylko target	0,469 (0,001)	−1,3	2,238 (0,047)	5,1
TFT	target i predyktory	0,481 (0,008)	−3,8	2,360 (0,195)	−0,1

W nawiasie: odchylenie standardowe MAPE między trzema ziarnami generatora (modele z elementem losowym); brak nawiasu oznacza model deterministyczny lub identyczne wyniki dla wszystkich ziaren. Poprawa: względna zmiana MAPE wobec prognozy naiwnej; wartość dodatnia oznacza model dokładniejszy od benchmarku.

7.2.2 Wykresy



Rysunek 3: USD/PLN: poprawa MAPE względem prognozy naiwnej na zbiorze testowym (wartości poza skalą oznaczono liczbą)



Rysunek 4: USD/PLN: prognozy na 30 dni notowań – model TFT (tylko target, średnia z trzech ziaren) i prognoza naiwna

7.2.3 Wnioski

Wyniki dla USD/PLN są jakościowo zbliżone do wyników dla EUR/PLN, ale korzystniejsze dla modeli uczenia maszynowego. Na horyzoncie jednego dnia różnice względem prognozy naiwnej są niewielkie: modele ARIMA, VAR i BVAR uzyskały poprawę od 0,4% do 0,7%, a modele ML wyniki od −4,1% do −0,3%. Na horyzoncie 30 dni lepsze od benchmarku okazały się modele VAR (5,6%), BVAR (5,5%), TFT w wariancie „tylko target” (5,1%) oraz XGBoost w obu wariantach (4,5% i 3,2%). Wskazuje to, że na dłuższym horyzoncie zarówno modele wielowymiarowe, jak i modele uczenia maszynowego są w stanie wykorzystać informację, której nie zawiera prognoza

naiwna.

Dodanie predyktorów nie poprawiło wyników sieci neuronowych – najsłabszy wynik dotyczy, podobnie jak dla EUR/PLN, sieci LSTM z predyktorami na horyzoncie 30 dni (−38,8%). Modele losowe były stabilne między ziarnami (odchylenie standardowe MAPE do 0,21 pkt proc., przy czym największe dla wariantów z predyktorami). Ścieżka prognoz TFT na rysunku 4 pokazuje, że prognozy modelu są przeważnie nieco niższe od prognozy naiwnej. W okresie testowym, w którym dominowało umocnienie złotego wobec dolara, przełożyło się to na mniejszy błąd; ocena, czy przewaga ta utrzyma się w innych warunkach rynkowych, wymaga testów na dłuższej historii i będzie elementem kolejnego etapu.

W infrastrukturze banku uruchomiono dla USD/PLN modele naiwny, ARIMA, VAR i BVAR dla obu horyzontów, model LSTM dla horyzontu 1 dnia oraz model TFT dla horyzontu 30 dni (rozdział 6).

7.3 Stopa procentowa

7.3.1 Zakres przetestowanych modeli

Stopę referencyjną NBP prognozowano w trzech ujęciach. W ujęciu dziennym przetestowano prognozę naiwną i model ARIMA oparty wyłącznie na historii stopy, dla horyzontów 1 i 30 dni roboczych. W ujęciu miesięcznym przetestowano prognozę naiwną, model ARIMA oraz modele VAR i BVAR, w których obok stopy występują WIBOR 3M i inflacja CPI r/r, dla horyzontów 1 i 12 miesięcy. Kierunek decyzji w kolejnym miesiącu (obniżka, brak zmiany, podwyżka) prognozowano modelami logit, probit, ordered logit i ordered probit, w wariancie opartym na samej stopie oraz w wariancie z predyktorami (inflacja CPI r/r, różnica między WIBOR 3M a stopą referencyjną i miesięczna zmiana kursu EUR/PLN, wszystkie z poprzedniego miesiąca). Wszystkie modele wygenerowały prognozy we wszystkich momentach prognozy zbioru testowego: 55 dla szeregu dziennego i 17 dla szeregu miesięcznego.

Ze względu na schodkowy charakter szeregu i wartości bliskie zera w latach 2020–2021 główną miarą jakości dla poziomu stopy jest MAE (podrozdział 5); wyniki przedstawiają tabele 10 i 11.

Tabela 10: Stopa referencyjna NBP: MAE poziomu stopy na zbiorze testowym i poprawa względem prognozy naiwnej

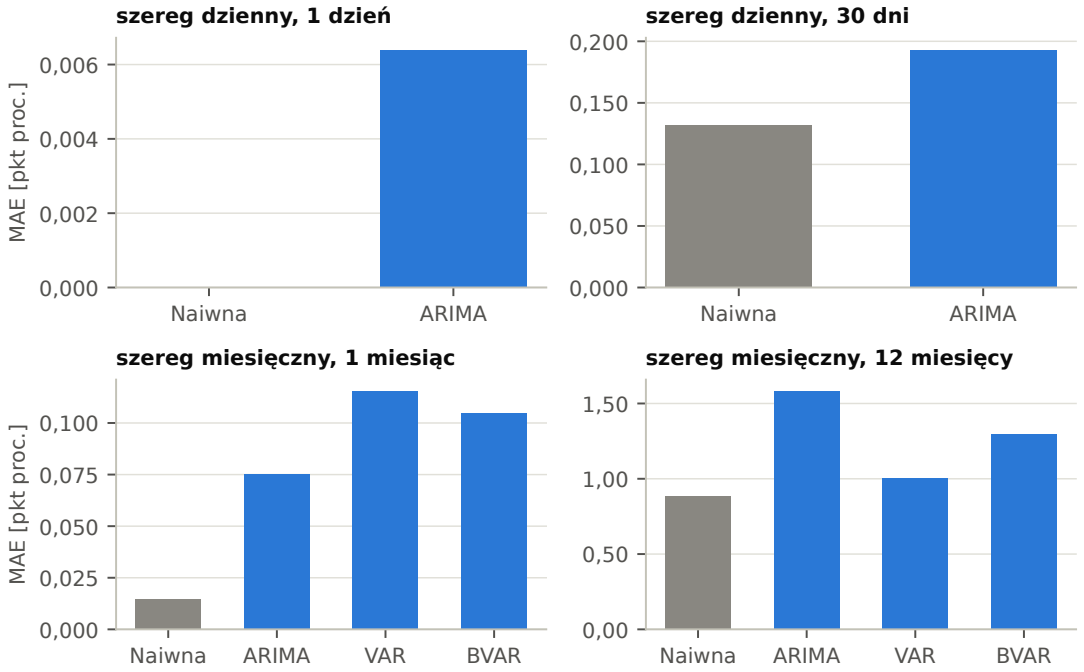
	horyzont krótki		horyzont długi	
Model	MAE [pkt proc.]	Poprawa [%]	MAE [pkt proc.]	Poprawa [%]
Szereg dzienny; horyzonty: 1 dzień i 30 dni				
Prognoza naiwna	0,000		0,132	
ARIMA	0,006	n/d	0,193	−46,6
Szereg miesięczny; horyzonty: 1 miesiąc i 12 miesięcy				
Prognoza naiwna	0,015		0,882	
ARIMA	0,075	−409,8	1,579	−79,0
VAR	0,115	−683,6	1,003	−13,6
BVAR	0,105	−611,6	1,298	−47,1

n/d – poprawy nie da się obliczyć, ponieważ błąd prognozy naiwnej jest równy zeru (stopa nie zmieniła się z dnia na dzień w żadnym momencie prognozy).

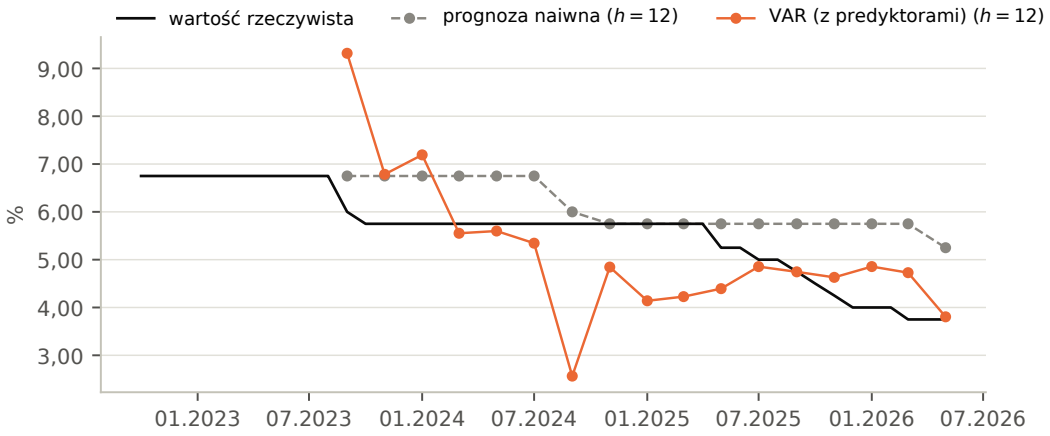
Tabela 11: Prognoza kierunku decyzji NBP na kolejny miesiąc: wyniki na zbiorze testowym (17 momentów prognozy)

Model	Wariant	Balanced Accuracy [%]	Macro-F1 [%]	Trafność [%]
Brak zmiany (benchmark)		50,0	48,5	94,1
Logit	tylko target	50,0	48,5	94,1
Logit	target i predyktory	43,8	30,1	82,3
Probit	tylko target	50,0	48,5	94,1
Probit	target i predyktory	43,8	30,1	82,3
Ordered logit	tylko target	50,0	48,5	94,1
Ordered logit	target i predyktory	96,9	65,6	94,1
Ordered probit	tylko target	50,0	48,5	94,1
Ordered probit	target i predyktory	96,9	65,6	94,1

7.3.2 Wykresy



Rysunek 5: Stopa referencyjna NBP: MAE poziomu stopy na zbiorze testowym według modelu i horyzontu



Rysunek 6: Stopa referencyjna NBP (szereg miesięczny): prognozy na 12 miesięcy – model VAR i prognoza naiwna

7.3.3 Wnioski

Wszystkie modele przeszły pełną procedurę backtestu i wygenerowały komplet prognoz, co potwierdza ich poprawność techniczną. Pod względem dokładności prognoza naiwna jest dla stopy procentowej bardzo trudnym benchmarkiem, ponieważ stopa przez większość czasu pozostaje niezmieniona: na horyzoncie jednego dnia jej błąd na zbiorze testowym wynosi zero, a modele ARIMA, VAR i BVAR mają na wszystkich horyzontach wyższe MAE (tabela 10). Najbliżej benchmarku jest model VAR na horyzoncie 12 miesięcy (MAE wyższe o 13,6%). Rysunek 6 pokazuje, że model VAR reaguje na zmiany inflacji i stóp rynkowych: już od 2024 r. prognozował obniżki stóp, które nastąpiły w latach 2025–2026, jednak z wyprzedzeniem i w części momentów prognozy ze zbyt dużą skalą, a w pojedynczych momentach prognozy dawał wartości odstające. W modelach VAR i BVAR na danych miesięcznych predyktory wykorzystano bez uwzględnienia opóźnienia publikacji, zgodnie z implementacją referencyjną; wyniki te potwierdzają działanie implementacji, natomiast ich interpretacja prognostyczna wymaga ostrożności.

W prognozie kierunku warianty oparte na samej stopie dają wynik równy benchmarkowi „brak zmiany", a modele logit i probit z predyktorami wypadają poniżej niego (tabela 11). Modele ordered logit i ordered probit z predyktorami trafnie wskazały jedyną zmianę stopy w zbiorze testowym (obniżkę), przy jednym fałszywym sygnale podwyżki. Ponieważ zbiór testowy obejmuje 17 momentów prognozy, z których tylko w jednym nastąpiła zmiana stopy, wynik ten nie przesądza o jakości prognoz kierunku, ale potwierdza, że modele uporządkowane poprawnie wykorzystują informację zawartą w predyktorach. Wszystkie modele dla stopy procentowej (wariant dzienny, miesięczny i kierunek decyzji) zostały uruchomione w infrastrukturze banku (rozdział 6).

7.4 Obligacje i krzywa rentowności

Modelowanie obligacji miało szerszy zakres niż modelowanie pozostałych wskaźników. Przedmiotem prognozy nie była jedna bezpośrednio obserwowana zmienna, lecz cała krzywa dochodowości. Krzywą należało najpierw oszacować na podstawie cen i przepływów pieniężnych dostępnych obligacji, następnie opisać za pomocą czynników, prognozować te czynniki i na końcu odtworzyć przyszłą krzywą oraz ceny instrumentów.

Proces obejmował dwa powiązane etapy. W pierwszym estymowano dzienne krzywe dochodowości i odpowiadające im parametry modelu Dynamic Nelson–Siegel. W drugim prognozowano

przyszłe wartości parametrów, rekonstruowano krzywą dla wskazanego horyzontu oraz oceniano wpływ prognozy na rentowności i ceny obligacji.

Prognozy czynników DNS wykonywano dla horyzontów wyrażonych w dniach roboczych. Horyzont 250D odpowiada w przybliżeniu jednemu rokowi i jest dalej określany również jako horyzont 1Y. Prognozowane czynniki wykorzystywano do rekonstrukcji całej krzywej dochodowości, dzięki czemu możliwe było wyznaczenie rentowności dla dowolnego terminu zapadalności. Wyniki lokalne oceniano zarówno dla całej krzywej, jak i dla wybranych tenorów. Do testów integracyjnych w infrastrukturze banku wykorzystano reprezentatywny podzbiór tenorów 3Y, 5Y i 6Y.

7.4.1 Zakres i przygotowanie danych

Podstawę estymacji krzywej stanowiły dane BondSpot obejmujące ceny obligacji, terminy zapadalności, kupony i przepływy pieniężne. Z około 128,7 tys. surowych rekordów, po zastosowaniu filtrów jakościowych, otrzymano około 94,7 tys. obserwacji obligacja–dzień. Próba obejmowała 94 instrumenty, w tym 58 obligacji kuponowych i 36 obligacji zerokuponowych.

Procedurę estymacji przeprowadzono dla 5 437 dni z okresu 2004–2026. W pojedynczym dniu wykorzystywano przeciętnie około 18 obligacji. Uwzględniano ceny clean oraz pełne przepływy pieniężne instrumentów. Obserwacje ważono z wykorzystaniem informacji o spreadzie, a wpływ nietypowych kwotowań ograniczano za pomocą odpornej funkcji straty.

Poza danymi obligacyjnymi analizowano informacje z rynku FRA i IRS, stopy procentowe i kursy walutowe, zmienne makroekonomiczne i globalne oraz wybrane informacje dotyczące aukcji i płynności. Nie wszystkie bloki były jednocześnie wykorzystywane w modelu końcowym. Ich wartość oceniano osobno dla poszczególnych czynników krzywej.

7.4.2 Estymacja krzywej dochodowości

Krzywą dochodowości reprezentowano za pomocą trzech czynników modelu Dynamic Nelson–Siegel:

$$y_t(\tau) = \beta_{0,t} + \beta_{1,t}\frac{1-\exp(-\lambda\tau)}{\lambda\tau} + \beta_{2,t}\left[\frac{1-\exp(-\lambda\tau)}{\lambda\tau} - \exp(-\lambda\tau)\right], \tag{1}$$

gdzie τ oznacza termin do zapadalności, natomiast $\beta_{0,t}$, $\beta_{1,t}$ i $\beta_{2,t}$ odpowiadają odpowiednio za poziom, nachylenie i krzywiznę krzywej.

Parametr λ ustalono na stałym poziomie 0,602, co odpowiada maksimum obciążenia czynnika krzywizny w okolicy 1,66 roku. Dzięki stałej wartości λ funkcje obciążenia tenorów pozostają niezmienne w czasie, a szeregi parametrów DNS mają porównywalną interpretację w całej próbie.

Dla każdego dnia dobierano wartości trzech parametrów tak, aby ceny obligacji wyznaczone przez krzywą były możliwie bliskie cenom obserwowanym. Otrzymano w ten sposób trzy dzienne szeregi czynników, które następnie traktowano jako zmienne docelowe w części prognostycznej.

7.4.3 Prognozowanie czynników DNS

Każdy czynnik prognozowano oddzielnie, ponieważ czynniki charakteryzują się odmienną dynamiką, przewidywalnością i zestawem użytecznych informacji. Jako podstawowy benchmark stosowano Random Walk, zgodnie z którym przyszła wartość czynnika jest równa jego ostatniej obserwowanej wartości.

W ramach screeningu porównano modele autoregresyjne i VAR, modele liniowe i regularyzowane, modele drzewiaste, metody redukcji wymiarowości, modele mean reversion oraz różne zestawy cech rynkowych i makroekonomicznych. Oceniano między innymi AR(1), VAR, Ridge, PLS, Random Forest, XGBoost, HistGradientBoosting, Extra Trees i PCA.

Najsilniejszy sygnał uzyskano dla czynnika nachylenia β_1. Model Ridge wykorzystywał informacje z rynku FRA i IRS, a jego prognozę stosowano warunkowo, gdy kierunek ruchu był potwierdzony przez sygnał rynkowy. W przeciwnym przypadku pozostawano przy prognozie Random Walk.

Dla czynnika poziomu β_0 Random Walk pozostał modelem głównym. Testowany model kontrolowanej zmiany poziomu dawał ograniczoną poprawę prognozy samego czynnika, lecz nie poprawiał jeszcze końcowej prognozy całej krzywej. Dla krzywizny β_2 model mean reversion uzyskiwał poprawę prognozy parametru, ale miał mniejszy wpływ na ceny obligacji.

7.4.4 Walidacja prognoz

Prognozy oceniano w schemacie walk-forward dla horyzontów 20, 60, 125 i 250 dni roboczych. W każdym momencie wykorzystywano wyłącznie obserwacje, których wartości docelowe były już znane. Imputer i scaler dopasowywano wyłącznie na zbiorze treningowym.

Modele porównywano z Random Walk na wspólnej próbie out-of-sample. Ocenę przeprowadzano kolejno na trzech poziomach:

1. błędu prognozy poszczególnych czynników DNS;
2. błędu zrekonstruowanej krzywej dochodowości;
3. błędu cen obligacji wyznaczonych na podstawie prognozowanej krzywej.

Dodatkowo wyniki analizowano według terminów zapadalności, lat testowych oraz wielkości błędu. Istotność różnic oceniano za pomocą estymatora HAC i bootstrapu blokowego z 5 000 replikacji.

7.4.5 Główne wyniki

Najsilniejszy wynik uzyskano na horyzoncie 250 dni roboczych. Na krótszych horyzontach Random Walk pozostawał bardzo wymagającym benchmarkiem, ponieważ zmiany czynników były zwykle niewielkie.

7.4.6 Wyniki według terminu zapadalności

Model poprawiał wyniki przede wszystkim w podstawowym zakresie do 10 lat. Dla obligacji powyżej 10 lat nie uzyskano stabilnej przewagi nad Random Walk. Segment ten obejmował mniejszą próbę i był traktowany jako diagnostyka ekstrapolacji, a nie jako podstawowy zakres oceny modelu.

7.4.7 Walidacja statystyczna

Statystycznie najmocniejsze były wyniki na poziomie czynników β_1 i β_2. Poprawa pełnej krzywej i cen obligacji była dodatnia ekonomicznie, ale przy poziomie istotności 5% pozostawała słabsza lub graniczna. Wyniki należy traktować jako rezultat etapu rozwojowego, ponieważ okres out-of-sample był również wykorzystywany podczas rozwoju architektury i selekcji wariantów modelu.

Tabela 12: Główne wyniki modelowania krzywej dochodowości

Poziom oceny	Horyzont	Poprawa względem RW	Interpretacja
Czynnik β_1: Ridge + filtr potwierdzenia	250D	36,3%	Najsilniejszy i statystycznie najlepiej potwierdzony wynik prognostyczny.
Czynnik β_2: mean reversion	250D	22,5%	Poprawa prognozy parametru, lecz mniejszy wpływ na wynik całej krzywej.
Pełna krzywa	250D	9,7%	Poprawa nachylenia była częściowo ograniczana przez błędy poziomu i krzywizny.
Krzywa w zakresie do 10 lat	250D	11,7%	Silniejsza poprawa w podstawowym zakresie oceny.
Ceny obligacji	250D	6,7%	Poprawa końcowej wyceny była mniejsza niż poprawa samego czynnika β_1.

Tabela 13: Wyniki według horyzontu prognozy

Horyzont	Poprawa prognozy β_1	Poprawa pełnej krzywej
60D	3,9%	2,5%
125D	7,8%	6,7%
250D	36,3%	9,7%

7.4.8 Diagnostyka błędów i ograniczenia

Największe błędy modelu nie były rozmieszczone równomiernie w czasie. Dla horyzontu 250 dni wszystkie obserwacje należące do 5% największych błędów rozpoczynały się w 2021 roku, a odpowiadające im daty docelowe przypadały na 2022 rok. Okres ten obejmował gwałtowne przejście z reżimu niskich stóp procentowych do inflacyjnego przeszacowania całej krzywej.

Błąd pełnej krzywej był w tym okresie silnie związany ze zmianami czynnika poziomu. Korelacja bezwzględnej zmiany β_0 z błędem krzywej wynosiła około 0,75. Eksperymenty diagnostyczne typu oracle wykazały, że nawet idealna znajomość przyszłego β_1 nie usuwa większości ekstremalnego błędu. Największy potencjał redukcji błędu znajdował się w czynnikach β_0 i β_2.

Zidentyfikowano trzy główne mechanizmy błędu:

1. zmianę reżimu, podczas której jednocześnie przesuwają się poziom i krzywizna;
2. błąd momentu, kiedy rynek sygnalizuje właściwy kierunek ruchu, ale realizacja następuje wolniej niż prognozuje model;
3. fałszywy sygnał, kiedy FRA lub IRS wskazują ruch, który ostatecznie nie materializuje się na krzywej.

Wyniki te uzasadniły zastosowanie filtra potwierdzenia dla prognozy β_1 oraz dalsze testy modeli wykrywających ryzyko dużej zmiany poziomu. Zmienne makroekonomiczne nie poprawiały stabilnie bezwarunkowej prognozy dokładnej zmiany β_0, ale wykazywały użyteczność jako wskaźniki reżimu i prawdopodobieństwa dużego ruchu.

Tabela 14: Błąd cen obligacji według terminu zapadalności, horyzont 250D

Segment	RMSE RW	RMSE modelu	Zmiana
0–2Y	2,34	2,04	+12,5%
2–5Y	6,47	5,93	+8,3%
5–10Y	11,20	10,66	+4,8%
10Y+	5,36	8,01	-49,3%

Tabela 15: Walidacja statystyczna najważniejszych wyników

Wynik	Poprawa	HAC p	Bootstrap p
β_1 Ridge, 250D	30,47%	0,0130	0,0174
β_1 z filtrem, 250D	36,28%	0,0027	0,0078
β_2 mean reversion, 250D	22,51%	0,0032	0,0114
Pełna krzywa, 250D	9,73%	0,0728	0,0886
Ceny obligacji, 250D	6,86%	0,0933	0,1074

W przypadku obligacji rezultatem nie był pojedynczy model szeregu czasowego, lecz kompletny proces obejmujący dane o instrumentach i przepływach, dzienną estymację czynników DNS, prognozę poziomu, nachylenia i krzywizny, rekonstrukcję przyszłej krzywej oraz ocenę prognoz na rentownościach i cenach obligacji.

7.5 WIG20

7.5.1 Zakres przetestowanych modeli

Dla indeksu WIG20 przetestowano dwa typy zadań. W prognozie poziomu indeksu oceniano model ARIMA (w wariancie z predyktorami jako regresję z błędami ARIMA) oraz XGBoost, w wariantach „tylko target" i „target i predyktory", względem prognozy naiwnej. W prognozie zmienności oceniano modele GARCH, EGARCH i GJR-GARCH z rozkładem t-Studenta, względem benchmarku zmienności historycznej. Zbiór testowy obejmuje sesje od 12.03.2024 do 17.09.2026, a backtest prowadzono z krokiem jednej sesji (599 momentów prognozy). Wszystkie modele wygenerowały komplet prognoz. W 57 z 599 momentów prognozy predyktory z rynku amerykańskiego były utrzymywane na ostatniej dostępnej wartości (tabela 2).

Tabela 16: WIG20: MAPE na zbiorze testowym i poprawa względem prognozy naiwnej

		$h = 1$		$h = 30$	
Model	Wariant	MAPE [%]	Poprawa [%]	MAPE [%]	Poprawa [%]
Prognoza naiwna	ostatnia wartość	1,017		4,668	
ARIMA	tylko target	1,019	−0,1	4,669	0,0
ARIMA	target i predyktory	1,009	0,8	4,669	0,0
XGBoost	tylko target	1,037	−2,0	5,928	−27,0
XGBoost	target i predyktory	1,038	−2,1	5,506	−17,9

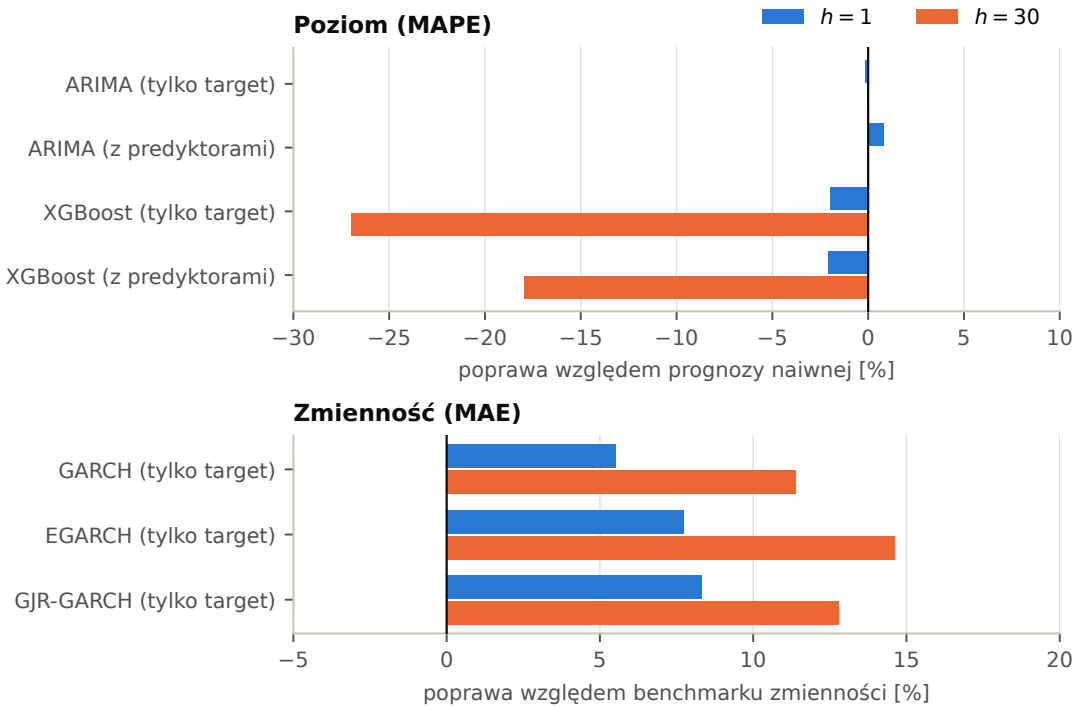
W nawiasie: odchylenie standardowe MAPE między trzema ziarnami generatora (modele z elementem losowym); brak nawiasu oznacza model deterministyczny lub identyczne wyniki dla wszystkich ziaren. Poprawa: względna zmiana MAPE wobec prognozy naiwnej; wartość dodatnia oznacza model dokładniejszy od benchmarku.

Tabela 17: WIG20: prognoza zmienności na zbiorze testowym

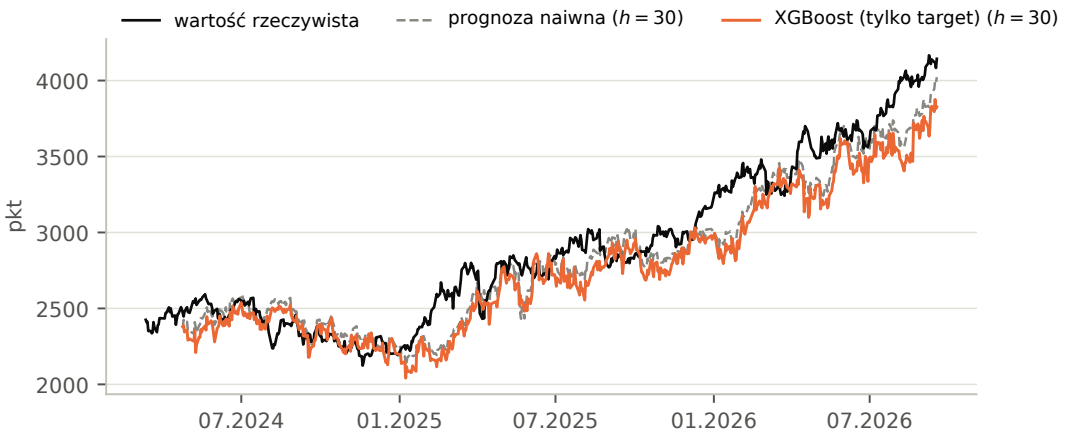
		$h = 1$			$h = 30$		
Model	Wariant	MAE	RMSE	Poprawa [%]	MAE	RMSE	Poprawa [%]
Benchmark	średnia 5 dni	1,901	3,304		2,033	3,683	
GARCH	tylko target	1,796	3,159	5,5	1,801	3,217	11,4
EGARCH	tylko target	1,754	3,127	7,7	1,735	3,227	14,6
GJR-GARCH	tylko target	1,743	3,125	8,3	1,773	3,230	12,8

Błędy prognozy wariancji warunkowej względem kwadratu dziennej logarytmicznej stopy zwrotu wyrażonej w procentach (jednostka: $\%^2$). Poprawa: względna zmiana MAE wobec benchmarku (średnia kwadratów pięciu ostatnich stóp zwrotu).

7.5.2 Wykresy



Rysunek 7: WIG20: poprawa względem benchmarku na zbiorze testowym – prognoza poziomu (MAPE) i prognoza zmienności (MAE)



Rysunek 8: WIG20: prognozy na 30 sesji – model XGBoost (tylko target) i prognoza naiwna

7.5.3 Wnioski

W prognozie poziomu WIG20 model ARIMA osiąga wyniki praktycznie równe prognozie naiwnej na obu horyzontach; w wariancie z predyktorami na horyzoncie jednej sesji uzyskał niewielką poprawę (0,8%). Model XGBoost jest słabszy od benchmarku, szczególnie na horyzoncie 30 sesji (−27,0% w wariancie „tylko target" i −17,9% z predyktorami). Rysunek 8 pokazuje źródło tej różnicy: w okresie testowym, zdominowanym przez silny trend wzrostowy indeksu, prognozy XGBoost były systematycznie niższe od bieżącego poziomu – model przenosił do prognozy wzorce zachowania indeksu z okresu treningowego. Predyktory częściowo ograniczyły ten efekt. Wyniki XGBoost były identyczne dla wszystkich ziaren generatora.

W prognozie zmienności wszystkie modele z rodziny GARCH były lepsze od benchmarku na obu horyzontach: poprawa MAE wyniosła od 5,5% do 8,3% dla jednej sesji i od 11,4% do 14,6% dla 30 sesji. Najlepsze wyniki uzyskały modele asymetryczne (GJR-GARCH dla $h = 1$, EGARCH dla $h = 30$), uwzględniające silniejszą reakcję zmienności na spadki cen, co jest zgodne z obserwacjami dla rynków akcji.

Wyniki dla WIG20 wyraźnie pokazują różnicę między trudnością prognozowania poziomu indeksu a dokładnością szacowania jego zmienności. O ile model uczenia maszynowego nie nadążał za silnym trendem wzrostowym, o tyle klasyczne modele z rodziny GARCH na obu horyzontach poprawiły prognozę zmienności względem benchmarku. Modele WIG20 nie były w bieżącym etapie przedmiotem przekazania do infrastruktury banku (rozdział 6).

7.6 Ropa

7.6.1 Zakres przetestowanych modeli

Targetem była cena ropy Brent (kontrakt najbliższy). W prognozie poziomu przetestowano model ARIMA, regresję wektorów nośnych (SVR), XGBoost i sieć LSTM – każdy w wariantach „tylko target" i „target i predyktory" – oraz model dekompozycyjny, w którym szereg rozkładany jest metodą VMD (*variational mode decomposition*) na pięć składowych prognozowanych modelem XGBoost. W prognozie zmienności oceniano modele GARCH, EGARCH i GJR-GARCH oraz model GARCH-MIDAS, łączący zmienność dzienną z miesięczną stopą Fed Funds jako zmienną niskiej częstotliwości. Zbiór testowy obejmuje sesje od 31.10.2023 do 1.09.2026, z krokiem jednej sesji (685 momentów prognozy).

Wszystkie modele, z wyjątkiem modelu dekompozycyjnego, wygenerowały komplet prognoz.

Model dekompozycyjny wyznaczył prognozy w około połowie momentów prognozy; jego implementacja wymaga dopracowania, dlatego wynik tego modelu podano w tabeli informacyjnie i nie uwzględniano go we wnioskach porównawczych.

Tabela 18: Ropa Brent: MAPE na zbiorze testowym i poprawa względem prognozy naiwnej

		$h = 1$		$h = 30$	
Model	Wariant	MAPE [%]	Poprawa [%]	MAPE [%]	Poprawa [%]
Prognoza naiwna	ostatnia wartość	1,677		8,156	
ARIMA	tylko target	1,682	−0,3	8,226	−0,8
ARIMA	target i predyktory	1,682	−0,3	8,150	0,1
SVR	tylko target	1,696	−1,1	8,657	−6,1
SVR	target i predyktory	1,714	−2,3	9,810	−20,3
XGBoost	tylko target	1,760	−5,0	8,174	−0,2
XGBoost	target i predyktory	1,757	−4,8	8,514	−4,4
LSTM	tylko target	1,700 (0,007)	−1,4	8,425 (0,449)	−3,3
LSTM	target i predyktory	1,708 (0,003)	−1,9	11,054 (0,698)	−35,5
VMD + XGBoost	tylko target	1,932*	−15,2	9,259*	−13,5

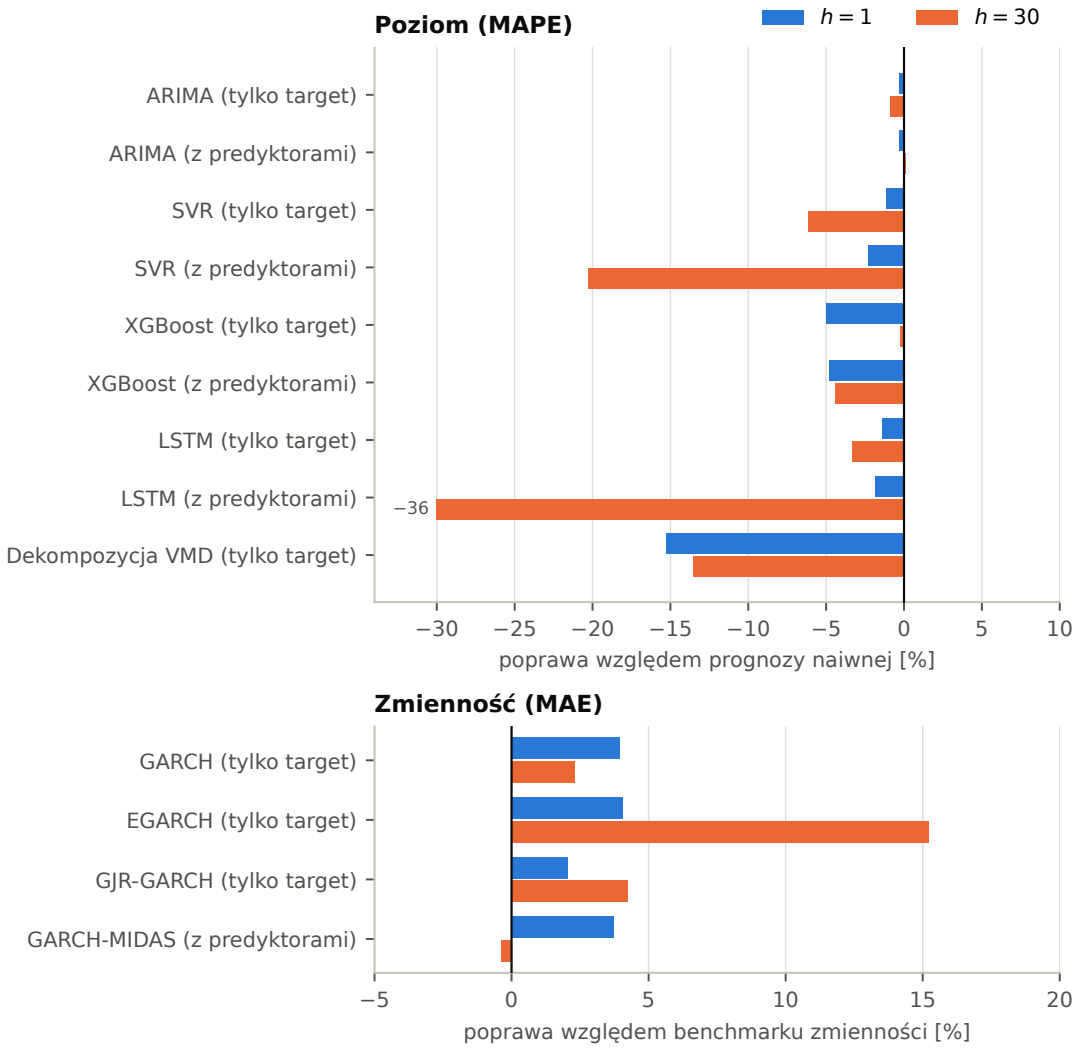
W nawiasie: odchylenie standardowe MAPE między trzema ziarnami generatora (modele z elementem losowym); brak nawiasu oznacza model deterministyczny lub identyczne wyniki dla wszystkich ziaren. Poprawa: względna zmiana MAPE wobec prognozy naiwnej; wartość dodatnia oznacza model dokładniejszy od benchmarku.
* Kompletność prognoz poniżej 100% (MAPE liczone z dostępnych prognoz).

Tabela 19: Ropa Brent: prognoza zmienności na zbiorze testowym

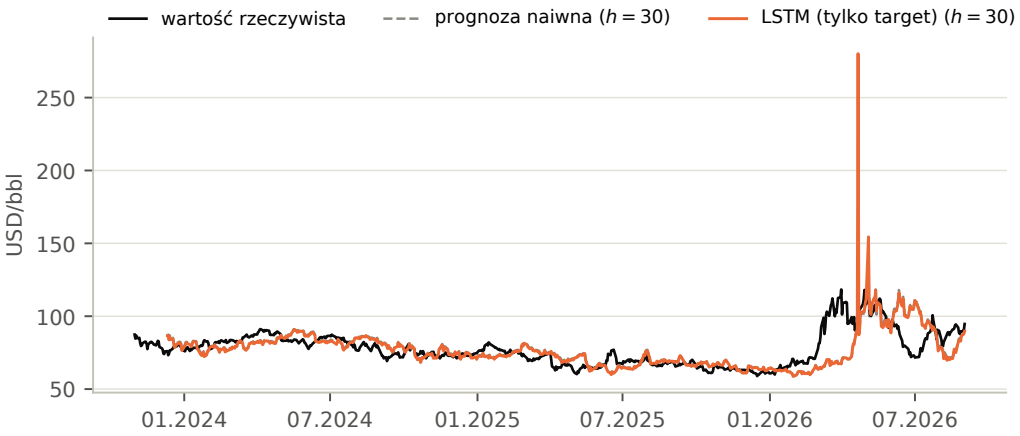
		$h = 1$			$h = 30$		
Model	Wariant	MAE	RMSE	Poprawa [%]	MAE	RMSE	Poprawa [%]
Benchmark	średnia 5 dni	6,585	16,912		7,759	19,638	
GARCH	tylko target	6,324	15,994	4,0	7,579	18,128	2,3
EGARCH	tylko target	6,317	16,302	4,1	6,578	17,623	15,2
GJR-GARCH	tylko target	6,449	16,209	2,1	7,429	18,126	4,3
GARCH-MIDAS	target i predyktory	6,339	16,065	3,7	7,788	18,580	−0,4

Błędy prognozy wariancji warunkowej względem kwadratu dziennej logarytmicznej stopy zwrotu wyrażonej w procentach (jednostka: $\%^2$). Poprawa: względna zmiana MAE wobec benchmarku (średnia kwadratów pięciu ostatnich stóp zwrotu).

7.6.2 Wykresy



Rysunek 9: Ropa Brent: poprawa względem benchmarku na zbiorze testowym – prognoza poziomu (MAPE) i prognoza zmienności (MAE)



Rysunek 10: Ropa Brent: prognozy na 30 sesji – sieć LSTM (tylko target, średnia z trzech ziaren) i prognoza naiwna

7.6.3 Wnioski

W prognozie poziomu ceny ropy modele uzyskały wyniki zbliżone do prognozy naiwnej lub od niej słabsze. Najbliżej benchmarku są modele ARIMA (od −0,9% do +0,1%) oraz XGBoost w wariancie „tylko target" na horyzoncie 30 sesji (−0,2%). Na horyzoncie jednej sesji wszystkie modele mieszczą się w przedziale do 5% gorszego MAPE. Dodanie predyktorów rynkowych nie poprawiło wyników na horyzoncie 30 sesji, a w przypadku SVR i LSTM wyraźnie je pogorszyło (−20,3% i −35,5%). Eksperymenty dla ropy uwidoczniły główne ryzyko prognozowania dynamicznego: błędy sieci neuronowych mogą się silnie kumulować w okresach gwałtownych zmian cen. Rysunek 10 ilustruje ten mechanizm: w okresie gwałtownego wzrostu cen ropy w marcu i kwietniu 2026 r. prognozy LSTM na 30 sesji, budowane krok po kroku z własnych prognoz modelu, w pojedynczych momentach przyjmowały wartości skrajne. Rozrzut wyników między ziarnami był niewielki na horyzoncie jednej sesji (odchylenie standardowe MAPE poniżej 0,01 pkt proc.) i większy na horyzoncie 30 sesji (0,45–0,70 pkt proc.).

Prognoza zmienności daje wyraźnie lepsze rezultaty: modele GARCH, EGARCH i GJR-GARCH były lepsze od benchmarku na obu horyzontach, a największą poprawę uzyskał EGARCH na horyzoncie 30 sesji (15,2%). Przewaga modelu EGARCH jest zgodna z silną, asymetryczną reakcją zmienności na rynku ropy na szoki cenowe. GARCH-MIDAS poprawił wynik na horyzoncie jednej sesji (3,7%), a na horyzoncie 30 sesji był zbliżony do benchmarku (−0,4%).

Dalsze prace dla ropy powinny skupić się na wprowadzeniu zabezpieczeń zapobiegających nierealistycznym odchyleniom prognoz na dłuższych horyzontach, np. ograniczeń prognozowanych stóp zwrotu. W infrastrukturze banku uruchomiono dla ropy modele SVR i LSTM dla obu horyzontów (rozdział 6).

7.7 Złoto

7.7.1 Zakres przetestowanych modeli

Dla ceny złota przetestowano w prognozie poziomu model ARIMA, XGBoost i sieć LSTM, każdy w wariantach „tylko target" i „target i predyktory", a w prognozie zmienności modele GARCH, EGARCH i GJR-GARCH z asymetrycznym rozkładem t-Studenta. Zbiór testowy obejmuje sesje od 10.10.2022 do 1.09.2026, z krokiem jednej sesji (951 momentów prognozy). Okres testowy obejmuje bezprecedensowy wzrost cen złota – z ok. 1700 do ponad 5300 USD za uncję na początku 2026 r. – oraz późniejszą korektę. Wszystkie modele wygenerowały komplet prognoz.

Tabela 20: Złoto: MAPE na zbiorze testowym i poprawa względem prognozy naiwnej

		$h = 1$		$h = 30$	
Model	Wariant	MAPE [%]	Poprawa [%]	MAPE [%]	Poprawa [%]
Prognoza naiwna	ostatnia wartość	0,883		5,196	
ARIMA	tylko target	0,913	−3,4	5,194	0,0
ARIMA	target i predyktory	0,910	−3,1	5,193	0,1
XGBoost	tylko target	0,899	−1,8	6,058	−16,6
XGBoost	target i predyktory	0,884	−0,1	6,010	−15,7
LSTM	tylko target	0,882 (0,001)	0,1	4,999 (0,009)	3,8
LSTM	target i predyktory	0,889 (0,004)	−0,7	5,715 (0,185)	−10,0

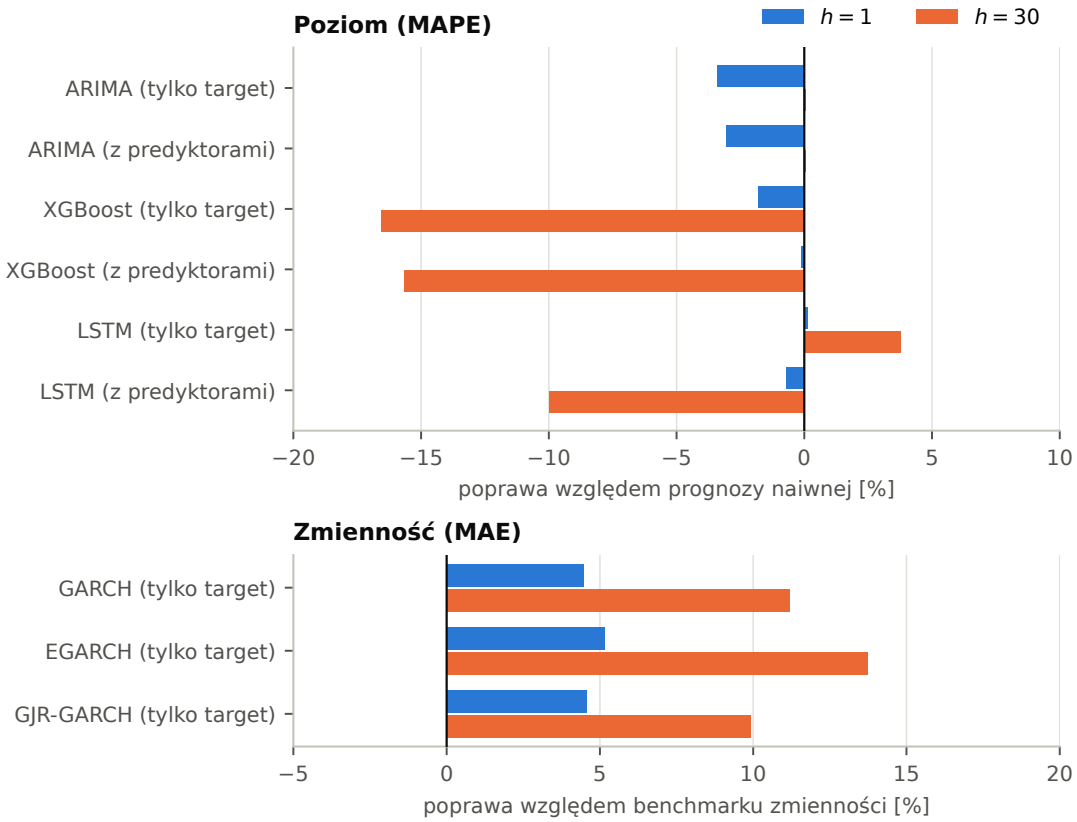
W nawiasie: odchylenie standardowe MAPE między trzema ziarnami generatora (modele z elementem losowym); brak nawiasu oznacza model deterministyczny lub identyczne wyniki dla wszystkich ziaren. Poprawa: względna zmiana MAPE wobec prognozy naiwnej; wartość dodatnia oznacza model dokładniejszy od benchmarku.

Tabela 21: Złoto: prognoza zmienności na zbiorze testowym

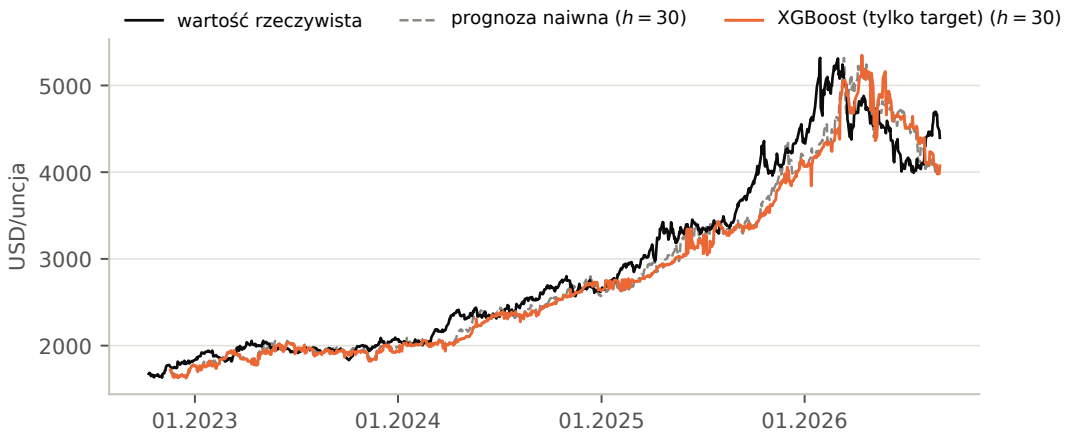
		$h = 1$			$h = 30$		
Model	Wariant	MAE	RMSE	Poprawa [%]	MAE	RMSE	Poprawa [%]
Benchmark	średnia 5 dni	1,842	5,436		2,063	5,855	
GARCH	tylko target	1,760	5,123	4,5	1,832	5,216	11,2
EGARCH	tylko target	1,747	5,101	5,2	1,779	5,215	13,8
GJR-GARCH	tylko target	1,758	5,103	4,6	1,858	5,210	9,9

Błędy prognozy wariancji warunkowej względem kwadratu dziennej logarytmicznej stopy zwrotu wyrażonej w procentach (jednostka: $\%^2$). Poprawa: względna zmiana MAE wobec benchmarku (średnia kwadratów pięciu ostatnich stóp zwrotu).

7.7.2 Wykresy



Rysunek 11: Złoto: poprawa względem benchmarku na zbiorze testowym – prognoza poziomu (MAPE) i prognoza zmienności (MAE)



Rysunek 12: Złoto: prognozy na 30 sesji – model XGBoost (tylko target) i prognoza naiwna

7.7.3 Wnioski

Na horyzoncie jednej sesji wyniki wszystkich modeli poziomu są bliskie prognozie naiwnej (od −3,4% do +0,1%). Na horyzoncie 30 sesji najlepszy wynik uzyskała sieć LSTM w wariancie „tylko target", która obniżyła MAPE o 3,8% względem prognozy naiwnej, przy niewielkim rozrzucie między ziarnami (odchylenie standardowe 0,01 pkt proc.). Dobry i stabilny wynik sieci LSTM na horyzoncie 30 sesji stanowi mocny punkt wyjścia do dalszego rozwoju modeli dla tego aktywa. Model ARIMA osiąga wynik równy benchmarkowi, natomiast model XGBoost jest na tym horyzoncie słabszy od benchmarku o ok. 16%. Rysunek 12 wskazuje prawdopodobną przyczynę: w okresie dynamicznego wzrostu cen prognozy XGBoost pozostawały poniżej bieżącego poziomu. Modele oparte na drzewach decyzyjnych, wybrane na walidacji w wariancie modelującym poziom ceny, nie ekstrapolują poza zakres wartości obserwowanych w danych uczących, co przy kolejnych rekordach cenowych prowadzi do systematycznego niedoszacowania. Wskazuje to na potrzebę modelowania stóp zwrotu zamiast poziomów w tej rodzinie modeli. Predyktory nie poprawiły wyników na horyzoncie 30 sesji.

W prognozie zmienności wszystkie modele były lepsze od benchmarku: poprawa MAE wyniosła 4,5–5,2% dla jednej sesji i 9,9–13,8% dla 30 sesji, przy najlepszym wyniku modelu EGARCH na obu horyzontach. Za najbardziej obiecujący kierunek dalszych prac dla złota uznano połączenie stabilizacji prognoz poziomu ceny, przez modelowanie stóp zwrotu zamiast poziomów, z oceną ryzyka za pomocą modeli z rodziny GARCH. W infrastrukturze banku uruchomiono dla złota model XGBoost (prognoza poziomu) i model GARCH (prognoza zmienności) dla obu horyzontów (rozdział 6).

7.8 BTC

7.8.1 Zakres przetestowanych modeli

Dla kursu BTC/USD przetestowano pięć rodzin modeli uczenia maszynowego i głębokiego uczenia: XGBoost, regresję wektorów nośnych (SVR), sieć LSTM, Temporal Fusion Transformer (TFT) oraz PatchTST (transformer operujący na fragmentach szeregu), każdą w wariantach „tylko target" i „target i predyktory" (predyktory z rynku akcji, dolara, rentowności UST 10Y i złota). Dla każdego wariantu wybierano jedną z czterech konfiguracji na zbiorze walidacyjnym i uruchamiano ją dla trzech ziaren generatora. Notowania BTC są dostępne 7 dni w tygodniu, dlatego horyzonty wynoszą 1 i 30 dni kalendarzowych. Zbiór testowy obejmuje okres od 1.09.2023 do 31.03.2025, z krokiem jednego dnia (549 momentów prognozy); jest to okres wcześniejszy niż

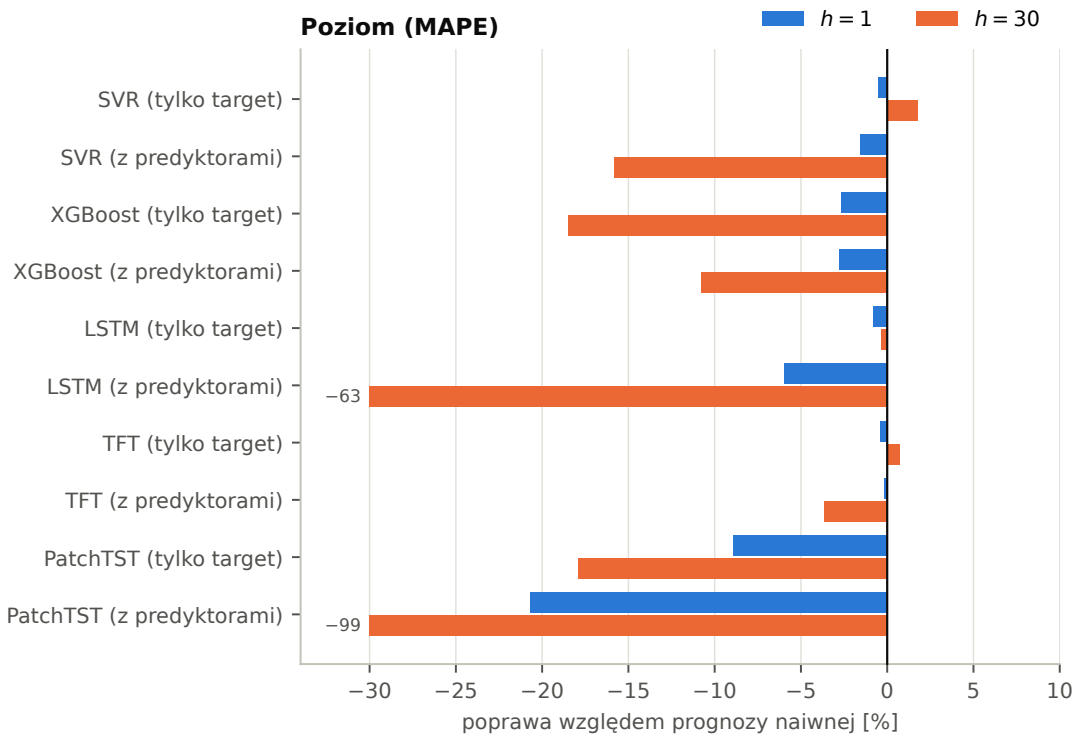
dla pozostałych wskaźników ze względu na zakres dostępnych danych. Wszystkie modele wygenerowały komplet prognoz. Dodatkowo zaimplementowano model Helformer i przeprowadzono dla niego przebieg walidacyjny; jego ocena na zbiorze testowym zostanie wykonana w kolejnym etapie.

Tabela 22: BTC/USD: MAPE na zbiorze testowym i poprawa względem prognozy naiwnej

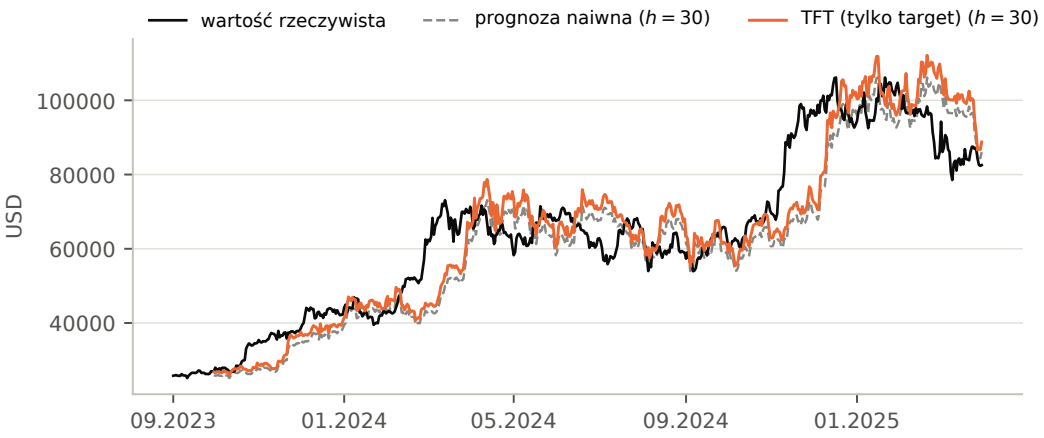
		$h = 1$		$h = 30$	
Model	Wariant	MAPE [%]	Poprawa [%]	MAPE [%]	Poprawa [%]
Prognoza naiwna	ostatnia wartość	1,852		11,246	
SVR	tylko target	1,862	−0,5	11,047	1,8
SVR	target i predyktory	1,881	−1,6	13,026	−15,8
XGBoost	tylko target	1,902	−2,7	13,324	−18,5
XGBoost	target i predyktory	1,903	−2,8	12,455	−10,8
LSTM	tylko target	1,867 (0,001)	−0,8	11,286 (0,101)	−0,3
LSTM	target i predyktory	1,962 (0,021)	−6,0	18,320 (0,907)	−62,9
TFT	tylko target	1,859 (0,004)	−0,4	11,166 (0,012)	0,7
TFT	target i predyktory	1,855 (0,001)	−0,2	11,654 (0,285)	−3,6
PatchTST	tylko target	2,017 (0,045)	−8,9	13,258 (1,022)	−17,9
PatchTST	target i predyktory	2,235 (0,040)	−20,7	22,368 (2,658)	−98,9

W nawiasie: odchylenie standardowe MAPE między trzema ziarnami generatora (modele z elementem losowym); brak nawiasu oznacza model deterministyczny lub identyczne wyniki dla wszystkich ziaren. Poprawa: względna zmiana MAPE wobec prognozy naiwnej; wartość dodatnia oznacza model dokładniejszy od benchmarku.

7.8.2 Wykresy



Rysunek 13: BTC/USD: poprawa MAPE względem prognozy naiwnej na zbiorze testowym (wartości poza skalą oznaczono liczbą)



Rysunek 14: BTC/USD: prognozy na 30 dni – model TFT (tylko target, średnia z trzech ziaren) i prognoza naiwna

7.8.3 Wnioski

Wszystkie modele zastosowane do prognozowania kursu BTC/USD działają poprawnie i wygenerowały komplet prognoz, a część z nich uzyskała dokładność lepszą od prognozy naiwnej. Kurs BTC/USD okazał się jednak wskaźnikiem, dla którego prognoza naiwna jest szczególnie trudna do poprawienia. Na horyzoncie jednego dnia wszystkie modele są od niej nieco słabsze; najbliżej benchmarku są TFT (w obu wariantach) oraz SVR i LSTM w wariancie „tylko target" (od $-0{,}2\%$ do $-0{,}8\%$). Na horyzoncie 30 dni lepsze od benchmarku okazały się SVR (1,8%) i TFT (0,7%) w wariancie „tylko target", a LSTM uzyskał wynik zbliżony do benchmarku ($-0{,}4\%$). Prognozy TFT na rysunku 14 podążają za trendem kursu, pozostając blisko prognozy naiwnej.

Dodanie predyktorów rynkowych w większości przypadków pogorszyło wyniki, co sugeruje, że w obecnym zestawie zmienne te wnoszą więcej szumu niż informacji o przyszłym kursie BTC; poprawę przyniosły jedynie w modelu XGBoost na horyzoncie 30 dni ($-10{,}8\%$ wobec $-18{,}5\%$) oraz, w niewielkim stopniu, w modelu TFT na horyzoncie 1 dnia. Najsłabsze i najmniej stabilne między ziarnami były modele PatchTST oraz LSTM z predyktorami na horyzoncie 30 dni (odchylenie standardowe MAPE od 0,9 do 2,7 pkt proc.), podczas gdy pozostałe modele losowe były stabilne (odchylenie standardowe do 0,3 pkt proc.).

Spośród zastosowanych metod najbardziej obiecujący jest model TFT, który przy stosunkowo krótkim czasie uczenia (z wykorzystaniem procesorów graficznych) osiąga na tle pozostałych modeli ponadprzeciętną dokładność, a wstępna analiza wskazuje, że wyraźnie korzysta ze zwiększenia liczby cech. Znacznej poprawy dokładności należy oczekiwać po rozszerzeniu zestawu cech o zmienne specyficzne dla rynku kryptoaktywów, w szczególności o wskaźniki sentymentu rynkowego i dane z analizy on-chain. Wyniki wskazują, że dla BTC priorytetem kolejnego etapu powinny być rozszerzenie i selekcja predyktorów, aktualizacja danych oraz strojenie architektur transformerowych. W infrastrukturze banku uruchomiono dla BTC modele XGBoost, SVR, LSTM i TFT dla obu horyzontów (rozdział 6).

7.9 Podsumowanie wyników

Tabela 23 zestawia wyniki wszystkich eksperymentów lokalnych. Łącznie oceniono 190 kombinacji modelu, wariantu danych i horyzontu (dla obligacji także tenoru), obejmujących 24 typy modeli – od modeli ekonometrycznych (ARIMA, VAR, BVAR, rodzina GARCH, modele wyboru dyskretnego, modele krzywej rentowności) po modele uczenia maszynowego i głębokiego ucze-

nia (XGBoost, SVR, lasy losowe, LSTM, TFT, PatchTST). Prognozy wygenerowano w pełnym zakresie dla 188 z 190 kombinacji; wyjątkiem jest model dekompozycyjny dla ropy, wymagający dopracowania implementacji.

Tabela 23: Zestawienie zbiorcze wyników na zbiorach testowych

Wskaźnik i zadanie	Miara	Konfig.	Kompletność	Lepsze	Najlepszy wynik względem benchmarku
EUR/PLN	MAPE	18	100%	5	BVAR ($h = 30$): 6,1%
USD/PLN	MAPE	18	100%	8	VAR ($h = 30$): 5,6%
Stopa NBP – szereg dzienny	MAE	2	100%	0	ARIMA ($h = 30$): −46,6%
Stopa NBP – szereg miesięczny	MAE	6	100%	0	VAR ($h = 12$): −13,6%
Stopa NBP – kierunek decyzji	BA	8	100%	2	modele uporządkowane z predyktorami: BA 96,9% (benchmark 50,0%)
Obligacje – rozszerzony proces DNS	RMSE	zob. sekcja 7.4	100%	–	Najsilniejszy wynik dla β_1: 36,3%; pełna krzywa: 9,7%; ceny obligacji: 6,7%
WIG20 – poziom	MAPE	8	100%	1	ARIMA ($h = 1$): 0,8%
WIG20 – zmienność	MAE	6	100%	6	EGARCH ($h = 30$): 14,6%
Ropa – poziom	MAPE	18	16/18 pełne	1	ARIMA ($h = 30$): 0,1%
Ropa – zmienność	MAE	8	100%	7	EGARCH ($h = 30$): 15,2%
Złoto – poziom	MAPE	12	100%	4	LSTM ($h = 30$): 3,8%
Złoto – zmienność	MAE	6	100%	6	EGARCH ($h = 30$): 13,8%
BTC/USD	MAPE	20	100%	2	SVR ($h = 30$): 1,8%

Konfig. – liczba ocenionych kombinacji model × wariant × horyzont (dla obligacji także × tenor), bez benchmarku. Lepsze – liczba kombinacji o mierze głównej lepszej niż benchmark. BA – Balanced Accuracy.

Z perspektywy celów zadania 1.4 najważniejsze jest potwierdzenie, że wszystkie rodziny modeli działają poprawnie w jednolitym, odtwarzalnym protokole oceny. Co do zasady modele korzystają wyłącznie z informacji dostępnej w momencie prognozy, generują kompletne prognozy dla horyzontów objętych daną konfiguracją i są porównywalne z benchmarkiem w identycznych warunkach. Wyjątkiem są modele oparte na miesięcznym panelu stopy procentowej, w których predyktory, w tym inflację CPI, wykorzystano bez uwzględnienia opóźnienia publikacji. Z tego względu ich wyniki prognostyczne mają charakter wstępny, choć potwierdzają poprawne działanie implementacji.

Pod względem dokładności prognoz wyniki układają się w spójny obraz:

- **prognoza zmienności** – modele z rodziny GARCH były lepsze od benchmarku w 19 z 20 przypadków, z poprawą do ok. 15% na horyzoncie 30 dni; to obszar o najbardziej stabilnej przewadze modeli;
- **krzywa rentowności** – modele czynnikowe DNS poprawiły prognozę naiwną w większości konfiguracji, najsilniej dla krótkiego końca krzywej;
- **kursy walut** – na horyzoncie 30 dni modele VAR i BVAR (oraz dla USD/PLN także TFT i XGBoost) obniżyły błąd o 3–6%, na horyzoncie 1 dnia wyniki są zbliżone do benchmarku;
- **ceny instrumentów rynkowych** (WIG20, ropa, złoto, BTC) – prognoza naiwna pozostaje trudnym benchmarkiem; pojedyncze modele (LSTM dla złota, SVR i TFT dla BTC) uzyskały przewagę na horyzoncie 30 dni, a część modeli ujawniła ograniczenia (brak eks-

trapolacji w modelach drzewiastych modelujących poziom, kumulacja błędu w prognozie dynamicznej sieci);

- **stopa procentowa** – prognoza naiwna dominuje dla poziomu stopy, natomiast modele uporządkowane z predyktorami poprawnie wskazały zmianę stopy w prognozie kierunku decyzji.

Zgodnie z charakterem etapu (podrozdział 5.4) wyniki te stanowią punkt odniesienia dla kolejnych prac. Zidentyfikowane obszary poprawy – selekcja i rozszerzenie zestawów predyktorów, systematyczny dobór hiperparametrów, modelowanie stóp zwrotu zamiast poziomów w modelach drzewiastych, zabezpieczenia prognoz wielokrokowych oraz aktualizacja danych (szczególnie dla BTC) – wyznaczają kierunki dalszego uczenia i parametryzacji modeli.

8 Podsumowanie realizacji zadania

W ramach zadania przygotowano i poddano wstępnemu procesowi uczenia, kalibracji oraz oceny grupę modeli prognostycznych dla uzgodnionych wskaźników. Prace objęły modele klasyczne, modele uczenia maszynowego i głębokiego uczenia, modele zmienności, modele klasyfikacyjne oraz modele krzywej rentowności.

Lokalne testy służyły potwierdzeniu poprawności implementacji, wstępnej kalibracji modeli oraz określeniu ich właściwości prognostycznych. Uzyskane wyniki pokazują, że skuteczność poszczególnych metod zależy od prognozowanego wskaźnika i horyzontu. W części przypadków modele poprawiały wynik względem benchmarku, natomiast w pozostałych prognoza naiwna pozostawała trudnym punktem odniesienia. Słabszy wynik prognostyczny nie oznaczał błędu technicznego implementacji.

Technicznie sprawne modele dostosowano do wspólnego interfejsu wykorzystywanego w infrastrukturze banku. W ramach dostępnych komponentów przeprowadzono testy integracyjne obejmujące uruchomienie modeli, odczyt danych, wykonanie procedur uczenia i predykcji oraz wygenerowanie wyników. Wyniki uzyskane w tym środowisku porównano z przebiegami referencyjnymi wykonanymi lokalnie.

Ze względu na trwającą przebudowę części infrastruktury chmurowej testy integracyjne nie obejmowały we wszystkich przypadkach pełnej publikacji produkcyjnego artefaktu. Zaliczenie testu oznacza zatem poprawne działanie modelu w zakresie dostępnych komponentów infrastruktury, a nie jego akceptację do zastosowania produkcyjnego.

Szczególnie rozbudowany zakres miały prace dotyczące obligacji, które objęły nie tylko prognozowanie, lecz także budowę dziennej reprezentacji krzywej dochodowości, rekonstrukcję przyszłej krzywej, wycenę instrumentów, walidację statystyczną oraz diagnostykę źródeł błędu.

Przeprowadzone prace zrealizowały cel zadania polegający na przygotowaniu grupy modeli, wykonaniu ich wstępnego uczenia i kalibracji, potwierdzeniu poprawności działania oraz dostosowaniu technicznie sprawnych implementacji do infrastruktury banku.

Przygotowane modele, konfiguracje, wyniki referencyjne i dokumentacja stanowią podstawę do dalszej kalibracji oraz późniejszego wyboru modeli w kolejnych etapach projektu.